



מדעים דיגיטליים להיי-טק

פרויקט מס' 205-1-24

דוח סופי

שם הפרויקט : CellenLink : חיזוי גשם חכם מבוסס דאטה סלולרי מרשת לינקים לקבוצת מחקר
cellenmonlab.

מבצעים :

שם - אופיר שלהבת ת"ז - 209190222

שם - שיר צוברי ת"ז - 207884792

מנחה : דרור יעקובי

מקום ביצוע הפרויקט : אוניברסיטת תל אביב

לשימוש המנחה :

הנני מאשר את תכנית העבודה המצורפת


שם - דרור יעקובי

חתימה -

תקציר

פרויקט זה מתמקד בשימוש בלינקים (חיבור אלחוטי בין שתי תחנות בסיס) סלולריים כתחנות מדידה אופורטוניסטיות למטרות חישה סביבתית ושיעורך תופעות מזג אוויר. בעשורים האחרונים, טכנולוגיות חישה מסורתיות, כגון רדארים ומדי גשם, הציגו מגבלות ברזולוציה זמנית ומרחבית ובדיוק הקרקעי. עם זאת, הלינקים הסלולריים, אשר פריסתם רחבה ומשמעותית, מציעים אלטרנטיבה חדשנית ועילה עם רזולוציה גבוהה יותר.

תופעות מזג אוויר כמו גשם, ערפל או שלג משפיעות על עוצמת האותות הסלולריים, וגורמות להנחתה באותות המשודרים בין תחנות בסיס. גישה זו, המכונה **Opportunistic Sensing**, מתבססת על דאטה המופק ממערכות קיימות שלא תוכננו לניטור סביבתי, וכך ממקסמת את השימוש במשאבים קיימים. ההנחה היא שניתן להשתמש בנתוני הנחתה אלה ליצירת כלי מדידה חדשני ומדויק למעקב אחרי שינויים סביבתיים ותנאי מזג אוויר. הרעיון מבוסס על גישות פורצות דרך שהציעה פרופ' חגית מסר בשנת 2006, לפיהן ניתן לנצל ערוצי תקשורת סלולריים (כגון קווי backhaul) למטרות ניטור סביבתי.



תמונות אלו מדגימות את הפוטנציאל של לינקים סלולריים לניטור סביבתי, באמצעות ניתוח השפעת תופעות מטאורולוגיות על עוצמת האות (RSL - RECEIVED SIGNAL LEVEL). הנתונים ממחישים כיצד נחות האות, שנגרם מתופעת מזג אוויר כמו גשם, ערפל, לחות ועוד, מאפשר לזהות ולנתח שדות גשם במרחב ובזמן, תוך הדגשת חשיבות מאפייני הלינקים והשפעתם על הדיוק.

הפרויקט משלב גישות מבוססות-מודל (Model-Driven) ומבוססות-נתונים (Data-Driven), תוך שימוש במודלים פיזיקליים כמו נוסחת ה-Power Law (נוסחה המתארת בקירוב את ההנחתה של המשקעים – מוצגת לעיל בתמונה), ובמקביל שילוב מודלים מתחום למידת מכונה. הגישות הנחקרות שואפות לשפר את דיוק המודלים הקיימים ולהתמודד עם אתגרי הניתוח של נתוני ניחות שנאספו ממערכות תקשורת.

מטרות הפרויקט כוללות:


1. פיתוח אלגוריתמים דטקציה ושערוך של גשם באמצעות ניתוח נתוני ניחות.
2. שילוב של מקורות נתונים שונים (כגון לינקים סלולריים ומדי גשם) ליצירת מודל חזק ומהימן.
3. חקר השפעות מאפייני הלינקים (כגון תדר, אורך, עוצמת ההנחתה) על ביצוע הדיטקציה והשערוך.



תכולת עבודה

הפרויקט מתמקד בפיתוח מערכת אינטגרטיבית לשערוך משקעים ולמיפוי שדות גשם במרחב ובזמן, תוך ניצול רשת לינקים סלולריים כסנסורים סביבתיים. הבסיס הפיזיקלי של המערכת נשען על נוסחת POWER LOW המתארת את הקשר בין עוצמת הגשם לניחות האותות בלינקים סלולריים. עם זאת, המודל הפיזיקלי המסורתי מוגבל בדיוקו ונדרש שיפור באמצעות שילוב טכניקות למידת מכונה וניתוח פיזיקלי מתקדם.

המוטיבציה לפרויקט נובעת מהצורך לשלב בין שלבי ההערכה והגילוי - Detection and Estimation - לשם שיפור דיוק האומדן של כמות הגשם המצטברת, תוך שימוש במדידות דעיכת אותות מקישורי מיקרוגל מסחריים (CMLs). השיטה עושה שימוש בפונקציית סיכון משולבת (RMSE, MAE, QWK), המענישה שגיאות הקשורות הן לשלב הגילוי והן לשלב ההערכה, ומאפשרת אופטימיזציה כוללת של התהליך. בניגוד לשיטות מסורתיות שבהן סף הגילוי מוגדר באופן שרירותי, השיטה המוצעת קובעת את סף הגילוי בהתאם לפונקציית הסיכון, תוך התחשבות באינטראקציה בין טעויות בשני השלבים. עבודה זו מדגישה את החשיבות של שילוב שלבים בתהליכי גילוי והערכה ואת היכולת למזער הטיות הנגרמות כתוצאה מהפרדת שלבים מסורתית.



מטרות

- פיתוח פונקציית מטרה משולבת המטפלת בו-זמנית בבעיות ההערכה והגילוי, בהתבסס על מאמר המצוין בהמשך.
- פיתוח מערכת מבוססת רשת לינקים מרובים (CML Network) לשיפור הדיוק לעומת לינק יחיד.
- ניתוח ביצועי המערכת במונחים של דיוק, זמן חישוב ורזולוציה במרחב ובזמן באמצעות מודלים פיזיקליים וטכניקות למידת מכונה.

שלבים למימוש הפרויקט

1. רקע תיאורטי - למידה מעמיקה של הרקע התיאורטי לפרויקט שיקלול מושגים בסיסיים וטכניקות מתקדמות:
 - מודלים סטטיסטיים - הבנה של סדרות זמן מרחביות, סטציונריות, ואוטו-קורלציה.
 - מודלים פיזיקליים - הבנה של נוסחת POWER LOW והשפעת מאפייני לינקים (תדר, מרחק) על הניחות תוך התייחסות לקשר הפיזיקלי בתהליכי שערוך וחיזוי בין נתוני הניחות לבין תופעות מזג אוויר המבוסס על רשת לינקים הקרובים זה לזה.
 - גישות מבוססות למידת מכונה/ מודלים/ שילוב ביניהם - האלגוריתמים שבהן נבצע את הפרויקט יהיו גם מודלים פיזיקליים (model-driven) גם data-driven וגם אפשרות לשלב ביניהם.
 - המחקר יכלול ניתוח, עיבוד המידע המרחבי בסביבה מרובת סנסורים:
 - ניתוח היתרונות בשימוש ברשת לינקים מרובים לשיפור דיוק החיזוי והפחתת שגיאות לעומת לינק יחיד.
 - ניצול ביג דאטה לעיבוד נתונים מרשתות סלולריות (מידע אפופרטוניסטי) בדגש על נתונים מרחביים וזמניים.


2. ניתוח דרישות מערכת - המערכת נדרשת להעריך משקעים בצורה מדויקת ולמפות שדות גשם במרחב ובזמן, $r^{\wedge}(t,y,x)$ תוך שילוב נתוני לינקים מרובים. עליה להיות מודולרית וגמישה, לתמוך בעיבוד נתונים מהיר תוך ניהול כמויות גדולות של נתונים מרשת לינקים. נדרשת דיוק גבוה, זמן חישוב קצר, והתמודדות עם רעש בנתונים הנגרמות מתופעות לא קשורות.

3. פיתוח אלגוריתמים ואיסוף נתונים - איסוף נתונים ועיבודם תוך שילוב אלגוריתמי למידת מכונה לפיתוח מודלים:

- איסוף נתונים מרשתות CML קיימות ושילוב נתונים מסימולציות עם נתוני אמת.
- ניקוי, פילטור והמרת הנתונים לפורמט אחיד תוך זיהוי והסרת תופעות לא רלוונטיות.
- פיתוח פונקציית מטרה משולבת, המטפלת בו-זמנית בהערכה וגילוי.
- פיתוח מנגנון לבחירה אופטימלית של לינקים קרובים בהתבסס על פרמטרים כמו מרחק, תדר, וצפיפות.
- שימוש במדדים כמו MAE ו-RMSE להערכת דיוק המודלים והשוואתם.
- בחינת תרומת לינקים נוספים לשיפור המערכת.
- יצירת הדמיות להצגת תוצאות.

שלב זה כולל שימוש בכלים לעיבוד נתונים כמו PANDAS, NUMPY כמו גם אלגוריתמים של למידת מכונה באמצעות ספריות כמו SCIKIT-LEARN ו-PYTORCH.

דיאגרמת בלוקים



איסוף נתונים ממדי גשם ולינקים

הפרויקט מתחיל באיסוף נתונים ממדי גשם ולינקים סולריים שנאספו בשוודיה בין יוני לספטמבר 2015. הנתונים מאוחסנים ב-Drive ומנותחים באמצעות Python.

חקירת נתונים

בשלב זה בוצעה חקירה מעמיקה של מאפייני הנתונים מהלינקים וממדי הגשם, כולל סטטיסטיקות תיאוריות של ממוצע, חציון, סטיית תקן, אחוזונים, איתור ערכים חסרים, כמות גשם יומית לכל מד גשם וכו'. נבדקו גם מדדים של מטא-דאטה כמו אורך לינקים, שיטות המדידה והמרחקים ממדי הגשם.

עיבוד נתונים

בשלב זה, נעשה עיבוד הנתונים לקראת ניתוח מתקדם והכנה למודלים, כולל ניקוי נתונים, מיפוי, חישוב הנחתה, והתאמת פורמטים של זמן. מבוצע מיזוג נתונים לאחר הסרת הנחתה חציונית קבועה והתאמת חלונות זמן כדי לאחד תוצאות ממקורות שונים.

בחינת מודלים לביצוע דקטציה

פיתחנו מודלי דקטציה כגון K-means, רגרסיה לוגיסטית, סף בסיסי, Random Forest, Gradient Boosting-I. המודלים נבדקים

לקביעת הדיוק לזמנים שונים, כגון יום, 8 ימים, חודש והתקופה כולה. כמו כן מבוצע בדיקת היפר פרמטרים לטיוב המודלים המתקדמים.

בחינת תוצאות

בשלב זה, ביצענו הערכת תוצאות המודל על ידי מדידת מטריקות כגון F1-Score, Accuracy, Precision, Recall. בסיום שלב זה, נבחרו שני מודלים, האופטימליים ביותר, לצורך המשך ביצוע משימת השערוך.

עד כה שלבים אלו מומשו בחלק הראשון של הפרויקט שהוצג בדוח אמצע.

בחינת מודלים לביצוע שערוך לפי קטגוריות

כאן הורחבה המטרה מעבר לזיהוי בינארי – אל סיווג עוצמות גשם לקטגוריות מוגדרות (ללא גשם, קל, בינוני, כבד) בהתבסס על הקריטריונים לעוצמת משקעים (נלקח מתוך הספר "Guide to instruments and Methods of Observation" של World Meteorological Organization עמוד 506). נעשה שימוש במודלים האופטימליים מהשלב הקודם - רגרסיה לוגיסטית ו-Gradient Boosting, תוך הנדסת פיצ'רים מתקדמת והטמעת איזון בין הקטגוריות. כל מודל הוערך לפי רגישות לכל קטגוריה, מדדי QWK, MAE, RMSE ועוד.

השוואה בין תוצאות Model-Driven לבין תוצאות Data-Driven

נערך השוואה בין שני כיווני ניתוח מרכזיים: האחד מבוסס על ידע פיזיקלי מוקדם (Model-Driven) והשני על למידה מתוך הדאטה בלבד (Data-Driven). בגישה ה-Data-Driven השתמשנו במודלים מוסברים כמו רגרסיה לוגיסטית, שנבנו תוך הבנה מוקדמת של התופעה הפיזיקלית – השפעת הגשם על אותות תקשורת סלולריים. כחלק מכך, ביצענו הנדסת פיצ'רים מותאמת כמו קצב שינוי ההנחתה, שונות, יחסים בין משתנים ועוד – שנועדו לשקף תופעות פיזיקליות ממשיכות. לעומת זאת, בגישה ה-Model-Driven השתמשנו במודל המבוסס על נוסחת Power Law, אשר קושרת בין עוצמת הגשם לבין מידת ההנחתה בתקשורת בצורה אמפירית על סמך התפלגות סטטיסטית בלבד – ללא התאמה אישית או הנחות מוקדמות על מבנה הקשר. נוסחה זו פותחה מתוך מחקרים בתחום אך הופעלה "כמו שהיא" על הדאטה – תוך התאמת פרמטרים בלבד לפי ערכי אמת.

רשת לינקים

בשלב זה עברנו מהתמקדות בלינק בודד לסביבה מורכבת יותר של רשת לינקים הסובבת את מד הגשם. מטרת השלב הייתה לבחון האם שילוב של מספר מקורות מידע (לינקים) הסמוכים גיאוגרפית, יכול לשפר את איכות התחזית, הן בזיהוי עצם קיומו של גשם (דטקציה), והן בשערוך עוצמתו (Classification Multi-Class).

סיכום תחזיות של המודל הנבחר – דטקציה ושערוך בשדה גשם לרשת לינקים

בשלב הסופי, הוחלט על מודל נבחר לביצוע תחזיות עתידיות. המודל הנבחר (רגרסיה לוגיסטית עם פיצ'רים) הופעל על רשת לינקים שלמה לצורך דטקציה ושערוך של עוצמת גשם על פני אזור מרחבי. נבחנה היכולת של המודל לפעול ברשת בצורה עקבית, תוך שילוב תחזיות בין לינקים סמוכים להשגת תחזית אחידה.

שינויים בדרישות הפרויקט

לאורך התקדמות הפרויקט, נדרשנו לבחון מחדש את התאמת המודל לדרישות המעשיות של חיזוי גשם. המודל שגיבשנו אמנם מצליח לבצע **דטקציה ושערוך** של אירועי גשם על בסיס משתני הנחתה סלולריים, אך יש להדגיש כי הוא מבוסס על **חלונות זמן מצטברים** ועל הנדסת פיצ'רים (כגון מגמות, שינויים וסטטיסטיקות לאורך זמן). כתוצאה מכך, המודל אינו מספק חיזוי מיידי על בסיס ערך בודד של הנחתה בזמן אמת, אלא פועל על מקטעי זמן ומתאים יותר לניתוח גשם בדיעבד.

בהקשר רחב יותר, המודל שלנו ממוקם תחת הקטגוריה של **Data-Driven Rainfall Estimation**, בשונה מגישות **Nowcasting** קלאסיות שמטרתן לספק תחזית כמעט-מיידי לאירוע גשם מתקרב. עם זאת, בשל השימוש בפריסט לינקים גיאוגרפית רחבה,

והגישה לנתונים זמינים בתדירות גבוהה, קיימת פוטנציאל משמעותי להרחיב את המודל בעתיד ליישומים בזמן אמת, כדוגמת חיזוי שיטפונות או Rainfall Nowcasting.

כפי שצוין במאמר "Rainfall Nowcasting Using Commercial Microwave Links (2020)":

"CMLs show potential for real-time rainfall monitoring and nowcasting, especially in regions where conventional radar is limited"

מודלים המבוססים על לינקים סלולריים יכולים להוות כלי יעיל לפתרונות תחזית בזמן אמת, במיוחד באזורים בהם תשתיות מכ"מ אינן מספקות כיסוי איכותי. שילוב אלגוריתמים נוספים עם עדכון דינמי של נתוני הלינקים, עשוי להוביל בעתיד לאפליקציות של nowcasting מבוסס לינקים, המתאימות לעולמות של חיזוי שיטפונות והתראות מוקדמות.

תוצרי העבודה

סיכום דוח אמצע - רקע והתקדמות עד כה

במסגרת הפרויקט נעשה שימוש בנתונים שנאספו משוודיה מחודשים 1.6.2015 ועד 1.9.2015. הכוללים מדידות ממדי גשם ונתוני לינקים סלולריים. המטרה המרכזית היא לבחון אפשרות לבצע זיהוי ושערוך של אירועי גשם על בסיס השפעתם על אותות תקשורת סלולרית - גישה שמציעה חלופה אופורטוניסטית וזולה יחסית לטכנולוגיות חישה מסורתיות.

בשלב הראשון, בוצעה חקירה מעמיקה ומקיפה של הנתונים משני מקורות - מדי גשם ולינקים סלולריים. מצד מדי הגשם, נבחנו מאפיינים סטטיסטיים שונים כמו ממוצע, חציון, סטיית תקן ואחוז ערכים חסרים ונמצא כי מרבית הדגימות מייצגות ימים יבשים מכאן שקיים חוסר איזון בין ימי גשם לימים יבשים - אתגר שעלול להשפיע על דיוק המודלים. במקביל נותחו גם נתוני הלינקים, הכוללים פרטים טכניים חשובים כמו אורכי לינק, כיווני שידור (A,B) ותדרים.

בשלב השני, בוצע עיבוד מתקדם לנתונים, שכלל מיפוי של לינקים קרובים לכל מד גשם, חישוב הנחתה (Attenuation) ונרמולה על ידי הפחתת ערך ההנחתה החציוני. כמו כן בוצעה התאמת פורמטים של תאריכים, סינון ערכים חריגים והתאמת חלונות זמן אחידים לצורך מיזוג בין מקורות הנתונים.

היעד היה לייצר תשתית קוהרנטית שתאפשר להחיל מודלים מבוססי דאטה תוך שימור הקשר הסביבתי בין אירועי גשם והנחתה.

בשלב השלישי, בוצע קישור בין לינקים למדי גשם על פי שיטת "מבפנים החוצה" מתוך יום ולינק בודד ועד לרשת שלמה של לינקים במגוון ימים. המטרה הייתה לייצר מודל דטקציה אופטימלי לזיהוי גשם.

במהלך שלב זה נבדקו מודלים שונים לזיהוי גשם עבור מד גשם Jarn ולינק 164, הלינק הקרוב ביותר למד גשם זה ביניהם: מודל סף (Threshold) פשוט, רגרסיה לוגיסטית בסיסית וכן שימוש במשתנים חדשים כגון ממוצע ושונות תוך הרחבת טווחי זמן לימים נוספים ולינקים אחרים (מד גשם Bergsj ולינק 552, שהינו קצר והינו הקרוב ביותר למד הגשם). בנוסף, נוסו מודלים מתקדמים כמו Gradient Boosting, Random Forest, K-Means, תוך כדי ניתוח ביצועים באמצעות מדדים כמו Recall, Accuracy, Precision, AUC ומדד סילואט. המטרה העיקרית באופטימיזציה של המודלים היא זיהוי אמין של ימי גשם ושיפור רגישות המודלים.

ממצאים ראשוניים הצביעו על כך כי בעוד מרבית המודלים מזהים טוב ימי יובש, קיימת עדיין מגבלה בזיהוי מדויק של ימי גשם. עם זאת השילוב בין פיצ'רים חדשים (ממוצע ושונות) והרחבת בסיס הנתונים (מיום בודד -> לשבוע -> לחודש -> לכלל התקופה) שיפרו את הביצועים, במיוחד ברגרסיה לוגיסטית ו-Gradient Boosting וכן מצאנו כי להם AUC הגבוהה ביותר לכלל טווחי הזמן וחלונות הזמן השונים שבחנו. נמצא כי מודלים אלה הם המועמדים המובילים להמשך.

מתוך תובנות אלו, הוגדרו שני כיווני פיתוח עיקריים להמשך:

1. משימת השערוך - מעבר ממודלים בינאריים לסיווג מולטי-קלאס של עוצמות גשם מדורגות.

2. משימת רשת לינקים - הרחבת המודל למרחבי תוך שילוב תחזיות ממספר לינקים סביב כל מד גשם לקבל תחזית אחודה מדויקת יותר.

משימת השערוך

עיבוד נתונים

- סיווג לקטגוריות

במשימת השערוך העמקנו את השימוש במודלים שנבחרו כמתאימים בשלב הקודם – רגרסיה לוגיסטית ו-Gradient Boosting בשילוב פיצ'רים של ממוצע ושונות בחלונות הזמן. בשלב זה נרצה לבחון את יכולתם לא רק לזהות האם ירד גשם, אלא **לשערך את כמות המשקעים בטווחים מוגדרים מראש** (Classification Multi Class). בשונה ממשימת הדטקציה העוסקת בזיהוי בינארי (גשם / לא גשם), כאן נדרש **לסווג את רמות הגשם לקבוצות קטגוריאליות: ללא גשם, גשם קל, גשם בינוני וגשם כבד** בהתאם לחלוקה לקטגוריות סוגי משקעים מתוך "8" WMO-No. "Guide to Instruments and Methods of Observation":

Rain (also showers)	$i < 2.5 \text{ mm h}^{-1}$	Slight
	$2.5 \leq i < 10.0 \text{ mm h}^{-1}$	Moderate
	$10.0 \leq i < 50.0 \text{ mm h}^{-1}$	Heavy
	$i \geq 50.0 \text{ mm h}^{-1}$	Violent ^b

*נציין כי במהלך בחינת המודלים הבנו כי הטווחים הנ"ל לא יוכלו לשקף בצורה מיטבית את הנתונים הקיימים של המדי גשם והלינקים ולכן החלטנו ליצור קטגוריה נוספת "NO RAIN" המצביעה על כך שאין גשם כלל תוך איחוד את הקטגוריות של "HEAVY" ו"VIOLENT" בשל מספר דוגמאות מצומצם בטווחים אלו.

במהלך בניית מערך הנתונים למודל, **עלתה סוגיה חשובה הנוגעת למהות המשתנה התלוי (מד הגשם)**. בעיבוד הנתונים שבוצע בשלבים הראשונים, יצרנו חלונות זמן של 5 דקות תוך חישוב הממוצע של ערכי מד הגשם עבור כל חלון זמן. אמנם גישה זו הייתה נוחה לאחידות ולעבודה עם הנתונים, אך עבור משימת השערוך – שבה אנו מעוניינים להעריך את **כמות הגשם שנצברה בפועל** – ממוצע אינו בהכרח הממד המתאים ביותר. בעקבות התובנה כי גשם הוא תופעה מצטברת בפרק זמן מסוים חישוב ממוצע על פני 5 דקות עלול "לדלל" את התופעה ולתת תמונה שאינה מייצגת את העוצמה הכוללת של האירוע.

לכן, כחלק ממשימת השערוך, בחרנו להשתמש ב**סכום** ערכי מד הגשם לכל חלון זמן. גישה זו משמרת את ההיבט המצטבר של הגשם ומתאימה יותר להקשר של חיזוי עוצמת משקעים – במיוחד כשמודל החיזוי נדרש לסווג את עוצמת הגשם לפי קטגוריות מצטברות שהוגדרו מראש.

- התאמת יחידות מידה למד הגשם - מ"מ לשעה

במהלך בניית מערך הנתונים למשימת השערוך, התברר כי קיים פער בין יחידות המדידה של מד הגשם לבין הספים שנקבעו לצורך סיווג עוצמות המשקעים. מד הגשם מספק נתונים ביחידות של **מילימטר לדקה** (mm/min), בעוד שהקטגוריות המוגדרות לשם הסיווג מבוססות על **מילימטר לשעה** (mm/h).

לכן, כדי לייצר התאמה בין היחידות ולהבטיח סיווג תקני של ערכי הגשם לקטגוריות הרלוונטיות, היה צורך **להמיר את מד הגשם מיחידות של מ"מ לדקה ליחידות של מ"מ לשעה**.

לצורך כך פותחה פונקציה ייעודית אשר מבצעת הכפלה של ערכי מד הגשם **בפקטור שמבוסס על גודל חלון הזמן** שנבחר לניתוח. מאחר ובמהלך עיבוד הנתונים בחרנו לאחד את הנתונים לחלונות זמן קבועים (למשל, כל 5 דקות), נדרש לחשב מהו

הפקטור המתאים להמרה. הפקטור מחושב לפי הנוסחה: **פקטור = מספר הדקות בחלון הזמן / 60** (כך למשל עבור חלון זמן של 5 דקות, פקטור = 12)
באמצעות פונקציה זו, כל ערך של מד הגשם מוכפל בפקטור המתאים, כך שניתן להתייחס לערכים כתואמים ליחידות מ"מ לשעה. באופן זה, ניתן לבצע **סיווג מדויק ואמין של כמות המשקעים לפי קטגוריות מוגדרות**, תוך השוואה נכונה בין ערך ה-Y של מד הגשם לבין תחזית המודל (Y החזוי).

מודלים- תהליך לבחירת מודל

כמו במשימה הקודמת, התחלנו את העבודה על בסיס טווח זמן מצומצם – שבוע אחד, מד גשם יחיד ושלושה לינקים בסביבתו, ובהמשך התרחבנו לבחינת מודלים גם על פני טווחי זמן ארוכים יותר ולינקים נוספים.

בשלב הראשון של משימת השערוך החלטנו להפעיל את המודל הבסיסי של רגרסיה לוגיסטית (שמצאנו בשלב הקודם הכולל את הפיצ'רים של ממוצע ושונות בלבד) לסיווג עוצמות גשם על פי הקטגוריות שהגדרנו:

- 0 מ"מ – אין גשם (0)
- 0–2.5 מ"מ לשעה – גשם קל (1)
- 2.5–10 מ"מ לשעה – גשם בינוני (2)
- מעל 10 מ"מ לשעה – גשם כבד (3)

בנוסף, כדי למנוע בעיות בסיווג, בוצע הסרה של קטגוריות נדירות המופיעות פחות מ-3 פעמים, כדי למנוע חוסר איזון בין סט האימון וסט הבדיקה. בהמשך, בוצעה חלוקה לסטים של אימון ובדיקה תוך שמירה על פרופורציה בין הקטגוריות (stratify). המודל שאומן מתבסס על שלושה משתנים על פני חלון זמן נבחר: **Variance, Adjusted Attenuation, Mean Attenuation** ו-**Attenuation**, כאשר כולם עברו נרמול.

לאחר האימון, המודל חזה הסתברויות לכל אחת מהקטגוריות, ומתוכן נבחרה הקטגוריה בעלת ההסתברות הגבוהה ביותר. להערכת המודל חושבו המדדים הבאים:

- **Confusion Matrix**: ניתוח שגיאות סיווג בין קטגוריות.
- **AUC לפי קטגוריה**: מדד AUC בודק את היכולת של המודל להבחין בין כל קטגוריה מסוימת לבין שאר הקטגוריות. ערכי AUC גבוהים מצביעים על כך שהמודל מצליח להפריד היטב את אותה עוצמת גשם מהשאר.
- **Accuracy כללי**: מדד כולל שמייצג את אחוז התחזיות הנכונות. בפרויקט זה, accuracy גבוה עשוי להיראות מרשים אך הוא עלול להטעות, במיוחד לאור חוסר האיזון בנתונים. לכן בניתוח התוצאות נתייחס אליו יחד עם מדדים נוספים כמו recall לקטגוריות הגשומות.

• Precision, Recall, F1-score לכל קטגוריה:

- **Precision (דיוק)**: מראה כמה מתוך התחזיות לקטגוריה מסוימת היו נכונות. מדד זה חשוב כדי להימנע מהתרעות שווא.
- **Recall (רגישות)**: בודק כמה מתוך האירועים האמיתיים של גשם בכל עוצמה זוהו בפועל – מדד חיוני כשמטרתנו היא לזהות כמה שיותר מקרים של גשם בפועל.
- **F1-score**: איזון בין דיוק לרגישות – רלוונטי במיוחד בפרויקט, כיוון שיש חשיבות גם למנוע פספוס גשם וגם לא להתריע לשווא.

● **מדדי שגיאה סדרתיים:**

בפרויקט זה, שבו מדובר בתחזית לקטגוריות בדירוג עוצמה עולה, חשוב לבדוק עד כמה המודל שוגה במרחק מהאמת:

- **MAE (שגיאה מוחלטת ממוצעת):** כמה רחוק בממוצע נמצאת התחזית מהקטגוריה האמיתית.

$$MAE = \frac{\sum_{i=1}^n |y_i - x_i|}{n} = \frac{\sum_{i=1}^n |e_i|}{n}$$

- **RMSE (שורש שגיאה ריבועית):** מדגיש שגיאות קיצוניות, ולכן מסייע לזהות מקרים שבהם המודל טעה בגדול (למשל תחזית של "אין גשם" בפועל של "גשם כבד").

$$RMSE = \sqrt{\frac{\sum_{i=1}^N \|y(i) - \hat{y}(i)\|^2}{N}}$$

- **NRMSD:** גרסה מנורמלת של RMSE – מאפשרת השוואה הוגנת בין תקופות שונות או ניסויים שונים.

$$NRMSD = \frac{RMSD}{y_{\max} - y_{\min}}$$

- **QWK-Quadratic Weighted Kappa:** לוקח בחשבון את המרחק בין הקטגוריות, ומעניש טעויות בין קטגוריות רחוקות יותר (למשל טעות בין "אין גשם" ל"גשם כבד" חמורה יותר מאשר טעות בין "קל" ל"בינוני").

$$QWK = 1 - \frac{\sum_{i,j} W_{i,j} O_{i,j}}{\sum_{i,j} W_{i,j} E_{i,j}}$$

- **ACC -** בודק כמה תחזיות היו בטווח שגיאה של קטגוריה אחת.

נציין בשלב זה כי המודלים שנבדקו בוצעו בחלונות זמן של 5 דקות. במהלך תהליך הפיתוח והאימון של המודלים שיוצגו בהמשך לביצוע משימת השערוך, התקבלה החלטה לבצע התאמה של הנתונים לחלונות זמן בגודל של 5 דקות. בחירה זו נבעה מאיזון בין מספר שיקולים ביניהם:

1. שמירה על רזולוציה גבוהה לזיהוי דינמיקה קצרת טווח

גשם, ובעיקר אירועי גשם קלים, נוטה להופיע באופן לא סדיר ולעיתים קצר מאוד בזמן. חלון זמן של 5 דקות מאפשר שמירה על רזולוציה מספקת לזיהוי ממטרים רגועים, בניגוד לחלון זמן ארוך יותר (10 דקות או יותר) שעלול לטשטש ולמחוק אירועים קצרי טווח, ובכך להוביל לאובדן אותות רלוונטיים.

2. תמיכה אמפירית – השוואת ביצועי מודלים

בחינה השוואתית של המודל על אותם הנתונים ברזולוציית זמן של 5 דקות לעומת 10 דקות הצביעה על יתרון מסוים לחלון הקצר יותר (נציין כי טענה זו נתמכת גם בשלב הראשון של הפרויקט שכלל בחירת מודלים לביצוע דטקציה)

עם זאת, חשוב לציין כי לא בכל המקרים נצפה יתרון מובהק לחלון זמן של 5 דקות. במקרים מסוימים, התוצאה שהתקבלה עבור חלון זמן אחר הייתה דומה ולעיתים אף טובה יותר. לכן, ניתן לומר כי רזולוציית הזמן האופטימלית עשויה להיות תלויה הקשר: היא תלויה בפרמטרים כגון אופי הנתונים, מאפייני הגשם באזור, איכות איסוף הנתונים, ועוצמת הרעש.

במקרה שלנו, ובהתאם לדאטה הספציפי שנבדק, חלון זמן של 5 דקות נמצא כמאוזן ואפקטיבי ביותר. יחד עם זאת, יש לשקול גמישות בהגדרת חלון הזמן כאשר מיישמים את המודל על אזורים או תרחישים אחרים.

3. הפחתת רעש מבלי לאבד פרטים

לעומת רזולוציה קצרה מדי (כמו דקה אחת), שמובילה לרעש רב מדי וחוסר יציבות במודל, רזולוציה של 5 דקות מאפשרת מיזוג נתונים מדויק ואמין יותר, תוך שמירה על איזון בין יציבות לבין רגישות לשינויים.

כעת נפרט על כל אחד מהמודלים שנבחנו:

1. מודל רגרסיה בסיסי

ניתוח תוצאות עבור חמישה ליניקים שונים בטווח זמן של 7 ימים - בחלון זמן של 5 דקות - 22-29.8.15

מדד שגיאה	163-Jarn	249-Jarn	530-Jarn	76-Lbom	552- Bergsj
MAE	0.035	0.046	0.119	0.089	0.058
RMSE	0.195	0.215	0.453	0.364	0.267
NRMSE	0.065	0.072	0.151	0.121	0.089
QWK	0.894	0.875	0.111	0.419	0.761

מסקנות

בשלב הראשון של ניתוח הבעיה יושם מודל רגרסיה לוגיסטית בסיסי, אשר התבסס על שני פיצ'רים עיקריים בלבד: ממוצע ההנחתה (Mean Attenuation) ושונוות ההנחתה (Variance of Attenuation). מודל זה הופעל על פני חמישה ליניקים שונים, בטווח של 7 ימים וברזולוציית זמן של 5 דקות. מטרתו הייתה לבחון האם ניתן לסווג את עוצמת הגשם על סמך מדדי עוצמה ליניאריים בלבד, תוך שימוש בגישה פשוטה ואחידה.

מניתוח תוצאות המודל עולה כי **קיימת שונות ניכרת בין הליניקים**. בליניקים כמו Jarn-163 ו-Jarn-249 התקבלו תוצאות טובות מאוד – מדדי שגיאה נמוכים (MAE ו-RMSE), וערכים גבוהים של QWK, אשר מעידים על יכולת הבחנה יציבה בין קטגוריות הגשם. מנגד, בליניקים כמו Jarn-530 ו-Lbom-76 נרשמו ביצועים נמוכים משמעותית, עם QWK נמוך מאוד (0.111 ו-0.419) וטעויות גסות בזיהוי העוצמות. **תופעה זו מצביעה על כך שהמודל הבסיסי מושפע בצורה בולטת מאיכות הסיגנל בליניק, תנאי השטח ורעש במדידות – גורמים שיכולים לפגוע בביצועי המודל כאשר לא נלקחים בחשבון משתנים נוספים.**

מעבר לתמונה הכמותית, ניתוח איכותי העלה כי המודל הבסיסי נוטה לסווג את מרבית הדגימות לקטגוריית "אין גשם" (קטגוריה 0), גם כאשר בפועל התרחשו אירועי גשם. בפרט, המודל מתקשה בזיהוי מדויק של גשמים בינוניים או כבדים – קטגוריות 2 ו-3 – שבהן נצפו ערכי Recall נמוכים או אפסיים. **התנהגות זו משקפת רגישות גבוהה של המודל לאי-איזון בין הקטגוריות, לצד מגבלה מהותית נוספת: היעדר התייחסות לדינמיקה בזמן.**

צעדים להמשך

המודל הבסיסי, בהיותו מבוסס על שני פיצ'רים רגועים בלבד, אינו מסוגל ללכוד תהליכים מתמשכים, תנודות קצרות טווח או שינויים פתאומיים – תכונות המאפיינות מאוד את התנהגות הגשם. הוא אינו "רואה" את התמונה הרחבה – לא את קצב ההשתנות, לא את המגמות בטווח של דקות או שעות, ולא את ההקשר ההיסטורי של הסיגנל. לכן, למרות פשטותו ויעילותו הראשונית, קיימת מגבלה בסיסית ביכולתו להתמודד עם מורכבות שערך וזיהוי גשם בצורה מיטבית.

מתוך נקודת מוצא זו, בשלב הבא בחרנו להרחיב את המודל כך שילכוד מגוון רחב של פיצ'רים נוספים – כגון נגזרות בזמן, ממוצעים נעים, שינויים פתאומיים, יחסים בין פיצ'רים, לגים (delays) ועוד. מטרת ההרחבה הייתה לאפשר למודל "לראות" אחורה בזמן", לזהות מגמות ולשפר את היכולת להבחין בין קטגוריות שונות, במיוחד כאשר מדובר באירועים קצרים או מעברים חדים בין עוצמות גשם.

חשוב לציין כי במקרים מסוימים, ההרחבה לפיצ'רים רבים לא הובילה בהכרח לשיפור מובהק בכל מדדי הדיוק – ולעיתים אף נרשמו עליות קלות ב-MAE או ירידה מסוימת בערך ה-QWK. עם זאת, גישה זו מאפשרת ייצוג עשיר יותר של המציאות, ומספקת בסיס מהימן יותר לשלב הבא: שילוב התחזיות על פני רשת של לינקים. נציין כי ערכי Label (תוצאות מדי הגשם) אינם בהכרח ערכי "אמת", אומנם זה המדד לפיו המודל לומד, אך ייתכן וגם עבורו נצפה לחוסר דיוק מסוים. אנו מאמינות כי המודל המשתמש בהיסטוריה ומדדים יכול להוות תמונה מדויקת יותר של המציאות אף ממדידות מד הגשם.

בנוסף, כאשר מסתכלים על רשת לינקים כמערכת כוללת, ניתן לפצות על טעויות מקומיות באמצעות הצלבה מרחבית – כלומר, לחזק תחזית מסוימת על סמך תחזיות מקבילות מלינקים סמוכים. גישה זו מתגברת על שגיאות שמקורן בלינק בודד, בין אם כתוצאה ממדידה שגויה, רעש או דפוס מקומי יוצא דופן. לפיכך, גם כאשר המודל המורחב אינו מושלם בפני עצמו, הוא מאפשר בנייה של מערכת תחזיות יציבה, עמידה ומדויקת יותר, בזכות יכולתו להשתלב בתוך מבנה רשת חכם.

2. מודל רגרסיה עם משקלים

בשלב זה החלטנו להרחיב את בדיקת מודל הרגרסיה הלוגיסטית כך שיתמודד טוב יותר עם האתגר המרכזי בפרויקט – חוסר האיזון בין הקטגוריות. מדובר במצב שבו רוב הדגימות משתייכות לקטגוריית "אין גשם", בעוד הקטגוריות של גשם קל, בינוני וכבד נדירות יותר.

כדי להתמודד עם חוסר האיזון הזה, בחרנו להפעיל את פרמטר 'class_weight=balanced' במודל הרגרסיה. פרמטר זה גורם לכך שכל קטגוריה תקבל משקל יחסי הפוך לשכיחותה – כלומר, קטגוריות נדירות יקבלו חשיבות גבוהה יותר בתהליך הלמידה של המודל. כך, המודל לא "יתעלם" מהקטגוריות הפחות שכיחות ולא ייטה באופן טבעי לבחור תמיד את הקטגוריה הרוב ("אין גשם").

מה היתרון בגישה זו?

- **התאמה למציאות של הפרויקט:** מאחר והנתונים מציגים רוב ברור של ימי יובש, איזון הקטגוריות מאפשר למודל להתמקד גם בזיהוי אירועי גשם – שהם המטרה המרכזית.
- **שמירה על שלמות הדאטה:** בניגוד לגישות כמו Oversampling או SMOTE שמוסיפות או מחקות דגימות, כאן כל הדאטה המקורית נשמרת, מה שמקטין את הסיכון ל overfitting (התאמת יתר).

*נציין כי במהלך גיבוש המודל, בחנו גם את השימוש בטכניקת Synthetic Minority Oversampling (SMOTE) (Technique) – שיטה ליצירת דגימות סינתטיות לקטגוריות נדירות, מתוך מטרה לאזן את התפלגות התוויות בקבוצת האימון. אמנם נמצא כי הטכניקה הצליחה לשפר את ייצוג הקטגוריות הגשומות באימון, אך בשל החשש מהתאמת יתר (Overfitting) כתוצאה מהוספת דגימות שאינן אמיתיות ובעקבות הרצון לשמר את שלמות הדאטה המקורי, הוחלט להמשיך בגישות מאוזנות אחרות.

- **פשטות ויעילות:** ניתן להפעיל את הגישה הזו בפשטות דרך פרמטר אחד במודל, ללא צורך ביצירת דאטה חדש.

לאחר הפעלת המודל עם משקלים מאוזנים, בחנו את ביצועיו מול מדדי הערכה שונים והשוונו אותם לביצועי המודל הבסיסי.

ניתוח התוצאות עבור חמישה לינקים שונים עבור 7 ימים -בחלון 5 דק - 22-29.8.15

מדד שגיאה	163-Jarn	249-Jarn	530-Jarn	76-Lbom	552- Bergsj
MAE	0.071	0.074	0.255	0.347	0.098
RMSE	0.267	0.296	0.675	0.920	0.323
NRMSE	0.089	0.099	0.225	0.307	0.108
QWK	0.829	0.803	0.433	0.290	0.793

מסקנות משלב זה

במטרה לאזן את התפלגות התחזיות, הופעל במודל פרמטר `'class_weight='balanced'`, אשר מקצה משקל גבוה יותר לקטגוריות הנדירות (ככל ששכיחותן נמוכה יותר). גישה זו שומרת על שלמות הדאטה המקורי, ללא צורך בהוספת דגימות סינתטיות, ומפחיתה את הסיכון ל-`overfitting`. יתרונה המרכזי טמון ביכולתה לאלץ את המודל "לשים לב" גם לאירועי גשם נדירים – שהם הליבה של משימת השערוך.

במבט ראשון, השימוש במשקלים מאוזנים אכן נראה מבטיח: נרשמה עלייה במדדי recall בקטגוריות הגשם, שיפור מדוד במדדי QWK בכמה מהלינקים, ולעיתים גם עלייה קלה בדיוק הכללי של המודל. לדוגמה, עבור לינק Jarn-530 עלה ערך ה-QWK מ-0.111 ל-0.433, ושופרו יכולות הזיהוי של גשם קל ובינוני.

עם זאת, ניתוח מעמיק יותר חשף תופעה מדאיגה: המודל נטה לסווג דגימות רבות כגשם – גם כשלא ירד בפועל. תופעת ה-`False Alarms` החרפה משמעותית, ונרשמה עלייה חדה במספר התחזיות השגויות לאירועי גשם. כך, לדוגמה, בלינק 163 נרשמו 34 טעויות מסוג False Positive (לעומת 4 בלבד במודל הבסיסי). אמנם מדובר ב"רגישות" גבוהה יותר, אך כזו שבאה על חשבון הספציפיות והאמינות של התחזיות.

הניתוח מבהיר כי במקרים רבים לא מדובר בשיפור אמיתי ביכולת החיזוי, אלא בהטיה עקבית של המודל לסווג גשם – גם כשאין לו ראיות מובהקות לכך. הדבר יוצר "אשליית שיפור", שבה עלייה מדומה בזיהוי קטגוריות גשם נסמכת על ריבוי תחזיות שווא.

כתוצאה מכך, גובשה ההבנה כי הדרך היעילה יותר לשפר את הביצועים אינה טמונה באיזון מלאכותי של הקטגוריות, אלא בשיפור איכות המידע שהוזן למודל. מתוך תובנה זו, בשלב הבא פיתחנו גרסה מתקדמת של המודל שאינה מסתמכת על איזון קטגוריות, אלא מבוססת על הנדסת פיצ'רים חכמה – הכוללת מידע על מגמות בזמן, שינויים פתאומיים, זיכרון היסטורי ויחסים בין מדדים שונים. באמצעות העשרת בסיס המידע, נשאף לאפשר למודל לזהות דפוסים מורכבים יותר של אותות גשם, ובכך לשפר הן את רמת הרגישות לאירועים אמיתיים והן את האמינות התחזיתית – מבלי להיכנס להטיות מבניות.

גישה זו תאפשר לנו להתמודד טוב יותר עם מורכבות המידע, תוך הפחתת תופעת ההתראות השגויות ושמירה על רמת דיוק גבוהה לאורך זמן.

3. מודל רגרסיה עם הנדסת פיצ'רים

לאחר שבחנו את ביצועי המודל הבסיסי ומודל רגרסיה עם משקלים ביחס לדאטה, עברנו לשלב מתקדם נוסף בפיתוח המודל – שילוב של הנדסת פיצ'רים (Feature Engineering). שלב זה נועד להעצים את יכולתו של המודל לאתר תבניות מורכבות ועמוקות יותר בהתנהגות הקשר בין גשם לאותות תקשורת סלולריים.

במהלך פיתוח המודל חתרנו להבנה מעמיקה של אופיו הייחודי של הדאטה שמקורו בלינקים. המידע שנאסף במערכות אלו רגיש מאוד לרעשים, תנודות פתאומיות ואנומליות שמקורן אינו בגשם ממשי – כמו שיבושי תדר, תקלות ציוד, מעבר אובייקטים פיזיים (למשל ציפורים או כלי רכב), ואפילו השפעות אטמוספריות רגעיות. **תצפית אחת בזמן מסוים עשויה להיות שגויה או מטעה, ולכן היה לנו ברור כי לא ניתן לבנות מודל מהימן על בסיס הסתכלות רגעית בלבד (בדיוק כפי שהוצג במודל הבסיסי).**

בהתאם לכך, בחרנו לבנות את הפיצ'רים של המודל תוך שימוש בגישה המבוססת על הקשר, המשכיות והקצנה מרחבית-זמנית. בעוד שהפיצ'רים הראשונים שיצרנו למודל – ממוצע ההנחתה והשונויות – משקפים את מצב הלינק ברגע מסוים, הפיצ'רים החדשים שנוספו אליהם מהווים נגזרות דינמיות המתארות את המגמות, התנודות והיחסים בין מדדים לאורך זמן. כך, המודל מקבל תובנות עשירות יותר על תהליך התפתחות הגשם, ולא רק על נקודה בודדת בזמן.

גישה זו גם תאמה את היעד המרכזי של הפרויקט – **דיוק מרחבי בשערור גשם תוך הסתמכות על רשת של לינקים, ולא על לינק בודד בלבד.** כדי להגיע לרמת דיוק מספקת בתנאים כאלה, נדרשנו לפתח פיצ'רים שיבטאו יציבות, רציפות ומבנה, ולא יגיבו לקפיצות רגעיות שעלולות להוביל לתחזיות שגויות. **השילוב בין תכונות גולמיות לדינמיות איפשר למודל להבין טוב יותר את ההקשר ולספק תחזיות מדויקות גם בתנאי שדה מורכבים ורועשים.**

הסבר על כל פיצ'ר

1. **Attenuation_Change_Rate** – שיעור השינוי בין ערכי ההנחתה העוקבים. מדד זה מזהה קפיצות פתאומיות בעוצמת ההנחתה, שיכולות להעיד על תחילת אירוע גשם או לחלופין על רעש חריג שדורש בקרה.
2. **Variance_Change_Rate** – שיעור השינוי בשונות ההנחתה. כאשר שונות עולה בחדות – ייתכן שמדובר באירוע חריג או בתחילת תנודתיות בגשם. לעומת זאת, ירידה עשויה להעיד על התייבבות.
3. **Attenuation_Mean_3** – ממוצע נע על פני 3 מדידות של ההנחתה. שימוש בממוצע נע מסייע להחליק תנודות חריפות ולאפשר למודל לזהות מגמות קצרות טווח. עוזר להבדיל בין "קפיצה רגעית" לבין מגמת גשם מתמשכת.
4. **Variance_Mean_5** – ממוצע נע של השונות לאורך 5 מדידות עוקבות. מדד זה מייצר אינדיקציה תנודתיות מתמשכת לאורך זמן. מאפשר לזהות "סביבה סוערת" באופן כללי.
5. **Attenuation_to_Variance_Ratio** – יחס בין ערך ההנחתה לבין השונות שלה. יחס גבוה מצביע על כך שעוצמת ההנחתה גבוהה יחסית לרעש – כלומר, סבירות גבוהה לגשם אמיתי. לעומת זאת, יחס נמוך עשוי להעיד על תנודתיות חשודה שיתכן ומייצגת רעש.
6. **Attenuation_Slope_5** – השיפוע של ערכי ההנחתה לאורך חמש נקודות זמן, המייצג את קצב השינוי המצטבר. הפיצ'ר מזהה מגמות התחזקות או דעיכה.
7. **Attenuation_Peakness_3** – פיצ'ר זה מחשב את ההפרש בין ערך נוכחי לבין ממוצע של 3 מדידות ($t-1, t-2$) ומזהה "שיאים" רגועים. הוא שימושי לאיתור קפיצות חריגות שעשויות לשקף גשם קצר וחזק במיוחד.
8. **Attenuation_Max_Min_Diff_5** – זהו הטווח בין הערך המקסימלי והמינימלי של ההנחתה בחלון של חמש נקודות זמן. הוא משקף תנודתיות גבוהה, ומסייע בזיהוי אירועי גשם סוערים או משתנים.
9. **Attenuation_to_PastMean_10** – הפיצ'ר בודק האם ערך ההנחתה הנוכחי גבוה או נמוך מהממוצע 10 מדידות קודמות לו כלומר 50 דקות. חריגה מהשגרה מהווה אינדיקציה לפעילות חריגה כמו תחילתו של גשם פתאומי.
10. **Attenuation_Acceleration** – נגזרת שנייה של ההנחתה, המודדת את שינוי הקצב של השינוי. הפיצ'ר מזהה האצה פתאומית בהנחתה – סימן אופייני לגשם שמתחיל בחדות.
11. **Attenuation_Shock_Count** – מונה את מספר ה"שוקים" (שינוי הנחתה גדול מ-0.5 בין שתי נקודות זמן סמוכות) שהתרחשו בעשר נקודות זמן קודמות. ריבוי שוקים עשוי להעיד על אזור גשם לא אחיד, סוער או מתפתח במהירות.
12. **Attenuation_Lag_1, Attenuation_Lag_2, Attenuation_Lag_3** – מייצגים בהתאמה את ערכי ההנחתה שהתרחשו צעד אחד, שניים ושלושה אחורה בציר הזמן (למשל 5, 10 ו-15 דקות לאחור כאשר חלון הזמן הוא 5 דקות).

ניתוח התוצאות עבור חמישה לינקים שונים עבור 7 ימים - בחלון 5 דק - 22-29.8.15

(דוגמא לתוצאות מוצגות בנספח 1)

מדד שגיאה	163-Jarn	249-Jarn	530-Jarn	76-Lbom	552- Bergsj
MAE	0.033	0.045	0.111	0.083	0.053
RMSE	0.182	0.211	0.436	0.354	0.251
NRMSE	0.061	0.070	0.145	0.118	0.084
QWK	0.905	0.882	0.298	0.537	0.806

מסקנות משלב זה

לאחר שבחנו את ביצועי המודל הבסיסי ואת מגבלותיו, עברנו לשלב מתקדם של פיתוח מודל המבוסס על הנדסת פיצ'רים עשירה. בניגוד למודל הראשוני שהתבסס על שני משתנים סטטיים בלבד – ממוצע ההנחתה ושונות ההנחתה – המודל החדש כלל מגוון פיצ'רים שתיארו שינויים לאורך זמן, מגמות, חריגות, האצה, תנודתיות, קצב שינוי ויחסים בין מדדים. מטרת השלב הזה הייתה להעמיק את הבנת המודל בנוגע לדינמיקת ההנחתה לשפר את היכולת להבחין בין רעש לאירועי גשם אמיתיים.

במבט כללי, התוצאות של המודל המשופר מעידות על מגמת שיפור ברוב הלינקים שנבדקו. לדוגמה, בלינק Jarn-163 התקבלו ערכי MAE ו-RMSE נמוכים מ-0.04 ו-0.20 בהתאמה, יחד עם QWK גבוה מאוד של 0.905 – תוצאה מרשימה המעידה על דיוק בהבחנה בין קטגוריות גשם שונות. גם בלינק Jarn-249 התקבלו תוצאות דומות, מה שמרמז על יכולת עקבית של המודל בלינקים מסוימים. לעומת זאת, בלינקים רועשים יותר כמו Jarn-530 או Lbom-76, אמנם נצפה שיפור במדדי recall עבור קטגוריות גשם נדירות, אך לא תמיד נרשמה ירידה משמעותית בשגיאות המוחלטות, ולעיתים אף התקבלה ירידה מסוימת ב-QWK.

תופעה זו מדגישה את אופיו המורכב של המידע: מודלים עשירים בפיצ'רים מסוגלים לשפר את הדיוק באירועים מאתגרים, אך רגישים יותר לאיכות הדאטה. במילים אחרות, ההרחבה לא תמיד מבטיחה שיפור בכל מדד ובכל לינק – במיוחד כאשר איכות הקלט נמוכה או הסיגנל חלש. אף על פי כן, גם במקרים בהם לא נרשם שיפור מדויק בערכים המספריים, ניתן היה לזהות צמצום בהתראות שווא או עליה בעקביות המודל לאורך זמן.

יתרה מזאת, היתרון המרכזי של המודל המשופר טמון ביכולתו להשתלב בעתיד כחלק ממערכת רחבה של רשת לינקים. מערכות כאלה, הנשענות על שילוב מידע מרחבי מאזורים סמוכים, צפויות "לכפר" על הטעויות של לינקים בודדים ולשפר את אמינות המודל הכוללת. כך, גם אם לינק מסוים סובל מתנודתיות חריגה, ניתן לאזן אותו על ידי מידע עקבי ממקורות סמוכים.

לסיכום, השלב של הנדסת הפיצ'רים סימן התקדמות משמעותית ביכולת החיזוי של המודל. הוא איפשר למודל להבין טוב יותר את ההקשר, לזהות תבניות מתפתחות ולשפר את רגישותו לאירועי גשם. אף שהתוצאות אינן מושלמות, הן מהוות בסיס מבטיח להמשך, שבו נשלב את המודל כחלק ממערכת מבוצרת ומרחבית – מתוך מטרה להגיע לשערוך מדויק, אמין ורלוונטי בזמן אמת.

4. מודל Gradient Boosting עם פיצ'רים חדשים

לאחר שבחנו את ביצועי מודל הרגרסיה הלוגיסטית המשופר שכלל פיצ'רים חדשים ומשקלים מאוזנים, עברנו לבחון מודל מתקדם נוסף – Gradient Boosting – תוך שילוב אותם פיצ'רים הנדסיים. מטרת השלב הייתה לבדוק **האם שיפור במורכבות המודל, יחד עם העשרת המידע הפנימי, יביא לדיוק טוב יותר ולרגישות גבוהה יותר באבחון עוצמות גשם שונות.** מודל ה-Gradient Boosting ידוע ביכולתו ללמוד דפוסים מורכבים ולא ליניאריים, תכונה חשובה במיוחד כשמדובר בקשרים

עדינים בין תכונות ההנחתה הסלולרית לבין אירועי גשם. שלב זה נועד להעריך האם מעבר למודל מורכב יותר יתרום באופן מובהק לדיוק הסיווג, ויהווה בסיס לבחירה במודל האופטימלי להמשך הפרויקט.

ניתוח תוצאות לחמישה לינקים שונים עבור 8 ימים - בחלון 5 דק - 22-29.8.15

מדד שגיאה	163-Jarn	249-Jarn	530-Jarn	76-Lbom	552- Bergsj
MAE	0.035	0.038	0.116	0.083	0.064
RMSE	0.186	0.203	0.438	0.359	0.290
NRMSE	0.062	0.068	0.146	0.120	0.097
QWK	0.903	0.887	0.322	0.550	0.745

מסקנות משלב זה

במטרה להעריך את תרומתו של מודל מתקדם יותר לתהליך השערוך, בחנו את ביצועי מודל Gradient Boosting תוך שילוב הפיצ'רים ההנדסיים שפותחו. היתרון המרכזי של מודל זה הוא ביכולתו לזהות דפוסים לא ליניאריים ומורכבים בין הפיצ'רים, במיוחד במקרים של תנודתיות ורעש בדאטה. עם זאת, ניתוח התוצאות מצביע על כך שהשיפור בביצועים לעומת מודל הרגרסיה הלוגיסטית אינו מהותי. בערכי דיוק ומדדי שגיאה שונים – כמו MAE, RMSE ו-QWK – התקבלו תוצאות דומות מאוד בין המודלים, ולעיתים אף עדיפות קלה למודל הפשוט יותר.

לצד זאת, יש לקחת בחשבון את החסרונות התפעוליים של Gradient Boosting – זמן ריצה ארוך, צורך בכויל פרמטרים מורכב, וירידה בשקיפות ההסבר למשתמש. לכן, למרות פוטנציאל ההשכלה שבו, מודל זה אינו מהווה בשלב זה חלופה מובהקת אלא תוספת שמחזקת את ההבנה בדבר חשיבות הפיצ'רים עצמם יותר מאשר מורכבות האלגוריתם.

בחירת מודל

לאחר ניתוח מקיף של מספר מודלים – החל ממודל הרגרסיה הלוגיסטית הבסיסי, דרך מודל עם משקלים מאוזנים, ועד למודלים מורכבים יותר הכוללים הנדסת פיצ'רים ומודל Gradient Boosting – הוחלט לבחור במודל הרגרסיה הלוגיסטית המשופר הכולל פיצ'רים דינמיים כמודל ההמשך ליישום ברשת הלינקים. הבחירה נעשתה מתוך איזון בין ביצועים טובים, יכולת הכללה, שקיפות פרשנית ויעילות חישובית. המודל הצליח לזהות תבניות חוזרות בגשם תוך התמודדות עם רעשים ותנודתיות, והוא מספק מסד חיזוי אמין ויציב שניתן להטמיע בקלות בתהליך מרחבי כולל.


בהמשך נבחן את ביצועי המודל על פני פרקי זמן רחבים יותר – תוך הערכה חוזרת של עקביות המודל בנתונים ארוכים ובתנאי שדה משתנים.

בחינת המודל הנבחר בטווחי זמן רחבים יותר

בהרחבת תחום התחזית לטווחי זמן ארוכים יותר – חודש ושלושה חודשים – נבחנה עמידותו ויציבותו של המודל הלוגיסטי המורחב מול אתגרי זמן, מגמה ותנודתיות אקראית. תוצאות הניתוח מצביעות על כך שהמודל מצליח לשמור על יציבות יחסית במדדי הביצוע המרכזיים לאורך זמן. ברוב הלינקים, ערכי השגיאה ($RMSE$ ו- $NRMSE$) נותרו דומים או אף השתפרו קלות בהשוואה לטווח הקצר של שבעה ימים, והפערים בין הטווחים לא היו מהותיים.

אמנם ניתן להבחין במספר סטיות מקומיות, בעיקר בלינקים בעלי רגישות גבוהה לרעש או מאפיינים ייחודיים (כמו לינק 530), אך סטיות אלו אינן שיטתיות ונראה כי המודל מצליח לייצר תחזיות עקביות גם תחת תנאים משתנים. חשוב להדגיש כי בפריסה עתידית של המודל ברשת לינקים, טעויות מקומיות מסוג זה צפויות להתאזן או להתקן בזכות חישוב משותף של מספר לינקים סמוכים – כך שהערכת הגשם תתבסס על תמונה רחבה יותר ולא על לינק בודד בלבד.

במובן זה, יציבות המודל לאורך זמן מהווה אינדיקציה לכך שהוא מסוגל להתמודד עם שינויים בטווח הארוך, ולהוות בסיס אמין להמשך פיתוח מערכת שערך גשם מרחבית, המבוססת על רשת של לינקים ולא על תחזיות נקודתיות.



[השוואה למודל הבינארי](#)

בהשוואה בין המודל הבינארי (שסיווג את הנתונים לשתי קטגוריות בלבד: גשם / אין גשם) לבין מודל המולטי קלאס שפיתחנו, מתקבלת תמונה מעניינת לגבי רמת ההסכמה ביניהם ויכולת החיזוי של כל אחד מהם. **ניתוח התוצאות עבור מספר לינקים מראה כי אחוז ההתאמה בין המודלים גבוה – סביב 85%-90% – דבר המלמד על עקביות במנגנון הזיהוי של אירועי גשם בכלל המערכת. (התוצאות עבור 2 לינקים מוצגות בנספח 2)**

למרות אחוז ההתאמה הגבוה, חשוב לציין כי במקרים בהם נרשמה חוסר התאמה, ברובם מדובר במצבים שבהם המודל הבינארי זיהה קיומו של גשם (תחזית 1), בעוד שהמודל המולטי-קלאס סיווג את המצב כ"לא ירד גשם" (קטגוריה 0). **תופעה זו מצביעה על כך שלמודל הבינארי יש רגישות מעט גבוהה יותר לאותות גבוליים – תכונה שעשויה להועיל באיתור גשם חלש או התחלה של אירוע גשם.** עם זאת, לא בכל תרחיש הבחירה במודל הבינארי בהכרח משפרת את הביצועים. ישנם מצבים שבהם התחזיות של הבינארי הובילו להתראות שווא (false alarms), במיוחד בלינקים רועשים יותר או בתנאים של תנודתיות גבוהה.

בהקשר של בניית רשת הלינקים, נמצא כי קיים פוטנציאל לשילוב מושכל בין תחזיות המודל הבינארי לבין אלו של המולטי-קלאס. המודל הבינארי מתאפיין ברגישות גבוהה לזיהוי גשם כלשהו (ללא הבחנה בין עוצמות הנחתה), ולעיתים מצליח לזהות אותות גשם חלשים או זליגה מאזור סמוך – מקרים שעלולים שלא להתבטא באופן מדויק במודל הקטגורי של אותו לינק. לכן, כאשר נמצאה חוסר התאמה בין המודלים – למשל כאשר הבינארי חזה גשם והמולטי-קלאס לא – הוחלט במקרים מסוימים "להעדיף" את התחזית הבינארית בשלב בניית הרשת. גישה זו נועדה לשפר את מהימנות התחזית המרחבית ולמנוע פספוס של אירועי גשם, במיוחד באזורים גבוליים. עם זאת, יש לציין כי השילוב אינו תמיד מועיל, והוא ינותח בהרחבה בפרק העוסק ברשת הלינקים.

השוואה ל-POWER LOW

בשלב זה בוצעה השוואה בין הגישה הפיזיקלית הקלאסית – נוסחת Power Law לחישוב עוצמות גשם – לבין המודל המתקדם שפיתחנו: רגרסיה לוגיסטית מולטי-קלאס עם הנדסת פיצ'רים. **מטרת ההשוואה הייתה לבחון עד כמה ניתן לסמוך על השיטה המסורתית לצורך סיווג רמות גשם והאם השימוש בלמידת מכונה מייצר יתרון משמעותי מבחינת דיוק, רגישות ואמינות התחזית.** נוסחת Power Law מבוססת על עקרון פיזיקלי המתאר את הקשר בין עוצמת אור תקשורת מונחת (attenuation) לבין עוצמת הגשם, לפי הנוסחה הבאה:

$$R = \left(\frac{A}{a * L} \right)^{\frac{1}{b}}$$

כאשר:

- R - עוצמת הגשם (במילימטר לשעה, mm/h)
- A - ההנחתה המתוקנת של אות השידור
- L - אורך הלינק (בקילומטרים)
- a, b - מקדמים תלויי תדר וקיטוב, שנקבעו לפי טבלת ITU

מקדמים אלה הוחשבו באופן פרטני לכל לינק בהתאם לתדר השידור ולקיטוב (Vertical / Horizontal), באמצעות פונקציית אינטרפולציה שהוגדרה בקוד. לאחר חישוב ערכי הגשם על פי הנוסחה, בוצע סיווג רב-קטגורי (Multiclass) על בסיס אותם ערכים של טווחי הסיווג שהוגדרו קודם לכן.

בשלב הבא, בוצעה השוואה מקיפה בין התוויות שהתקבלו בשיטה זו לבין אלו שהתקבלו ממודל הרגרסיה הלוגיסטית, באמצעות מיזוג טבלאות לכל לינק ובדיקת אחוז ההתאמה, כמו גם דיוק של כל שיטה מול תוויות מד הגשם עצמו. המדדים שנבחנו: אחוז חוסר ההתאמה בין השיטות, אחוזי דיוק לפי ערך האמת, דיוק בזיהוי אירועי גשם בלבד ($Gauge > 0$).

תוצאות ההשוואה:

מדדים	163-Jarn	249-Jarn	530-Jarn	76-Lbom	552- Bergsj
PL מודל בין התאמה הרגרסיה הלוגיסטית	70.58%	56.20%	59.50%	60.17%	30.41%
PL מודל לבין ערכי מד הגשם	30.91%	44.46%	42.81%	40.33%	70.08%
PL מודל בין התאמה הרגרסיה הלוגיסטית לבין ערכי מד הגשם	96.69%	95.54%	92.40%	93.72%	95.21
PL מודל גשם בדיק באירועי גשם בלבד של מודל	44.90%	38.78%	38.78%	7.32%	7.41%
PL מודל גשם בדיק באירועי גשם בלבד של מודל רגרסיה לוגיסטית	61.22%	53.06%	12.24%	21.95%	55.56%

ההשוואה בין מודל ה- $Power\ Law$ הפיזיקלי למודל הרגרסיה הלוגיסטית עם הנדסת פיצ'רים ממחישה את הפער הקיים בין גישות תיאורטיות מסורתיות לבין שיטות למידת מכונה מבוססות דאטה. בעוד נוסחת PL נשענת על עקרון פיזיקלי פשוט יחסית לקשר בין עוצמת אות לשיעור גשם, היא מתקשה לעמוד ברמות הדיוק הנדרשות בסביבה רועשת ומורכבת כמו רשתות תקשורת אלחוטיות. במרבית הלינקים שנבחנו נצפה כי מודל זה נטה להפריז בזיהוי אירועי גשם – פעמים רבות קבע שהתרחש גשם גם כשמד הגשם הצביע על יובש מוחלט. תוצאה זו הובילה לשיעורי דיוק נמוכים, ובמיוחד לפגיעות באמינות כשמדובר באירועים קריטיים.

לעומת זאת, מודל הרגרסיה הלוגיסטית הפגין יתרון מובהק, כשהצליח להתאים את עצמו לדפוסים ייחודיים בכל לינק – כולל תנודתיות, רעש, מגמות היסטוריות ושינויים פתאומיים. שיעורי ההתאמה למד הגשם היו גבוהים במיוחד, והמודל הפגין איזון טוב בין רגישות וספציפיות, כלומר לא רק שזיהה את מרבית אירועי הגשם, אלא גם שמר על זהירות ולא יצר יותר מדי התראות שווא. יתרה מכך, מודל זה נבנה כך שיוכל לפעול בצורה עקבית לאורך זמן, תוך שמירה על גמישות ללמידה מתמשכת באזורים משתנים.

עם זאת, חשוב לציין כי נוסחת PL, למרות מגבלותיה, אינה חסרת ערך: היא פשוטה ליישום, ואינה מצריכה תהליך אימון. במקרים של חוסר דאטה או בצורך לקבל הערכה ראשונית מהירה, היא יכולה לשמש כאינדיקטור גס. אבל כאשר יש זמינות של דאטה איכותי ומטרה לספק תחזיות מדויקות ורובוסטיות – הבחירה במודל הלוגיסטי נראית ברורה.

לסיכום, ההשוואה מעידה כי מודל הרגרסיה הלוגיסטית, על אף היותו מורכב יותר, מספק תחזית מהימנה ומבוססת דאטה. הוא מהווה בסיס יציב להמשך בניית רשת לינקים חכמה, תוך אפשרות לשלב את נוסחת PL כתוספת בלבד – ולא כמודל מוביל.

רשת לינקים

בשלב האחרון של הפרויקט עברנו מניתוח לינק יחיד אל שילוב מידע ממספר לינקים סביב כל מד גשם - כלומר ניתוח מרחבי. המטרה הייתה לנצל את הפריסה המרחבית של הלינקים לשיפור יכולת הזיהוי וההערכה של אירועי גשם. לצורך כך, פיתחנו תהליך הכולל עיבוד מקדים של נתוני הלינקים וחישוב תחזיות גשם עבור כל לינק בנפרד באמצעות מודל הרגרסיה הלוגיסטית המשופר שהצגנו קודם לכן ולאחר מכן כלל התחזיות מכל הלינקים שולבו לכדי תחזית סופית אחודה באמצעות מדד חציוני. כך עברנו מנקודת תצפית בודדת לרשת מקומית היכולה המעניקה מידע עשיר ומדויק יותר על מצב המשקעים בסביבת כל מד גשם. המטרה בגישה זו היא להעשיר את בסיס התחזיות על ידי שילוב מידע מלינקים מרובים, ובכך להקטין את התלות בנתון נקודתי אחד ולאפשר ניבוי אמין, יציב ומייצג יותר של עוצמות גשם באזור גאוגרפי נתון.

תיאור התהליך

1. עיבוד נתוני הלינקים הקרובים

ראשית, השתמשנו בפונקציה שביצעה את כל שלבי העיבוד הדרושים:

- שליפת כל הלינקים שנמצאים בטווח מרחק מקסימלי (למשל רדיוס של 1 ק"מ) ממד הגשם.
- עיבוד מידע גולמי מתוך קבצי הדאטה: חישוב ערכי ההנחתה (Attenuation) ולכידותם לחלונות זמן אחידים (5 דקות).
- מיזוג נתוני כל לינק עם נתוני מד הגשם הקרוב.
- התאמת יחידות מד הגשם (למ"מ לשעה) על פי פקטור זמן.

כך נבנתה עבור כל לינק טבלה מסודרת, המתאימה להצגת מודלים על בסיס אחיד.

2. הרצת מודל רגרסיה לוגיסטית לכל לינק

בשלב הבא, הופעלו מודלים של רגרסיה לוגיסטית מולטי-קלאס לכל לינק בנפרד. כל לינק נמדד בנפרד והמודל חזה לכל חלון זמן את עוצמת הגשם הצפויה: אין גשם, גשם קל, גשם בינוני, או גשם כבד וזאת בהתאם לטווחי הגשם שהוגדרו קודם לכן.

3. שילוב התחזיות לרשת לינקים

לבסוף, הופעלה פונקציה אשר:

- אספה את התחזיות מכל הלינקים באותו זמן.
- חישה את החציון של התחזיות כדי לקבוע את התחזית הסופית (החציון נבחר כדי לצמצם השפעה של תחזיות קצה חריגות ולשמר את רוחב המידע).
- יצרה טבלה משולבת לכל חלון זמן, הכוללת את התחזית המשולבת ואת מדדי הביצוע שלה (דיוק, MAE, RMSE, QWK).

גישה זו מבוססת על ההנחה כי ריבוי מדידות סביב המד משפר את היכולת לנטר את הגשם בפועל, תוך צמצום טעויות הנובעות מלינקים חריגים או בעיות מדידה נקודתיות.


בדיקת ביצועים ברשת לינקים בטווחי רדיוס שונים

לאחר בניית רשת הלינקים סביב מדי הגשם, ביצענו ניתוחים על פני שני מדי גשם נבחרים במטרה להעריך את תרומת הרחבת הטווח המרחבי על איכות התחזיות. לכל מד גשם נבחנו שלוש רמות רדיוס – רדיוס קטן (1 ק"מ), בינוני (1.5 ק"מ) ורדיוס גדול (3 ק"מ). עבור כל רדיוס, שילבנו את תחזיות הלינקים שנמצאו בטווח באמצעות חישוב חציון הקטגוריות, ולאחר מכן בחנו את התוצאות על פי מדדי ביצועים שונים.

אחת ממטרות המפתח בפיתוח רשת הלינקים הייתה לשפר את מהימנות התחזית המרחבית, תוך הקטנת התלות בתוצאה של לינק בודד. כפי שנראה בשלבים הקודמים, קיימים לינקים שמהם התקבלו תחזיות פחות מדויקות – בין אם בשל רעש במדידה, מאפיינים טופוגרפיים, או מגבלות במודל הספציפי שהופעל עליהם. הסתמכות בלעדית על לינקים כאלו עלולה להוביל לשגיאות בזיהוי או בשערוך עוצמת הגשם. רשת הלינקים, לעומת זאת, מאפשרת לגבש תחזית אחודה על סמך מידע שמגיע ממספר

מקורות במרחב – וכך לנטרל השפעות חריגות של לינקים בעייתיים. בכך, נוצרת מערכת חיזוי יציבה ואמינה יותר, שמייצגת טוב יותר את המצב האמיתי בשטח. גישה זו אינה רק מתאימה למצבי שגרה, אלא גם מגבירה את הרובסטיות של המערכת בתנאים משתנים או בעת תקלות במדידה, ומספקת יכולת להצליב ולתקף תחזיות על בסיס מידע סמוך. עם זאת, לקחנו בחשבון כי שילוב לינקים ממרחקים גדולים מדי עלול להכניס רעש – במיוחד כאשר קיימים פערים במזג האוויר בין אזורים גיאוגרפיים שונים. לכן יש צורך בבחינה גמישה של רדיוס.

נוכל להציג לדוגמא את המיפוי המרחבי של מד הגשם JARN בעבור מס' לינקים הקרובים אליו:



ניתוח התוצאות עבור 7 ימים - בחלון 5 דק - 22-29.8.15

מדד שגיאה	1 Km Jarn (6 לינקים)	1.5 Km Jarn (6 לינקים)	2 Km Jarn (18 לינקים)	1 Km Bergsj (4 לינקים)	1.5 Km Bergsj (14 לינקים)	2 Km Bergsj (20 לינקים)
MAE	0.043	-	0.041	0.040	0.046	0.046
RMSE	0.207	-	0.219	0.207	0.230	0.230
QWK	0.878	-	0.859	0.880	0.828	0.828
recall Category 1	0.48	-	0.52	0.74	0.68	0.68
recall Category 2	0.63	-	0.63	0.71	0.35	0.35
recall Category 3	0.00	-	0.00	0.33	0.00	0.00

ניתוח התוצאות עבור חודש -בחלון 5 דק - 01.08.15-01.09.15

מדד שגיאה	1 Km Jarn (6 לינקים)	1.5 Km Jarn (6 לינקים)	2 Km Jarn (18 לינקים)	1 Km Bergsj (4 לינקים)	1.5 Km Bergsj (14 לינקים)	2 Km Bergsj (20 לינקים)
MAE	0.021	-	0.022	0.025	0.022	0.021
RMSE	0.147	-	0.156	0.159	0.150	0.148
QWK	0.843	-	0.822	0.826	0.836	0.845
recall Category 1	0.44	-	0.41	0.43	0.47	0.49
recall Category 2	0.59	-	0.59	0.68	0.55	0.61
recall Category 3	0.00	-	0.00	0.00	0.00	0.33

ניתוח התוצאות עבור 3 חודשים -בחלון 5 דק - 01.06.15-01.09.15

מדד שגיאה	1 Km Jarn (6 לינקים)	1.5 Km Jarn (6 לינקים)	2 Km Jarn (18 לינקים)	1 Km Bergsj (4 לינקים)	1.5 Km Bergsj (14 לינקים)	2 Km Bergsj (20 לינקים)
MAE	0.025	-	0.025	0.026	0.025	0.024
RMSE	0.162	-	0.164	0.166	0.161	0.160
QWK	0.776	-	0.757	0.824	0.827	0.826
recall Category 1	0.41	-	0.39	0.39	0.42	0.43
recall Category 2	0.56	-	0.49	0.65	0.57	0.57
recall Category 3	0.00	-	0.00	0.43	0.43	0.43

ניתוח תוצאות רשת הלינקים – סיכום ומסקנות

בהשוואת ביצועי רשת הלינקים על פני טווחי זמן שונים (שבוע, חודש, שלושה חודשים) ורדיוסים מרחביים מגוונים (1 ק"מ, 1.5 ק"מ, 2 ק"מ), התקבלה תמונה מורכבת אך עקבית למדי, המצביעה על יתרונות מובהקים לגישת הרשת – במיוחד כאשר היא בנויה בצורה ממוקדת ואיכותית.

1. יציבות לאורך זמן וזיהוי אירועים משמעותיים

ראשית, ניכר כי ביצועי רשת הלינקים שמרו על יציבות לאורך זמן. ערכי MAE ו-RMSE נותרו נמוכים ואחידים, גם כאשר חלונות הזמן התארכו משבוע לשלושה חודשים. מדדי איכות כמו QWK המשיכו להעיד על רמת התאמה גבוהה בין התחזית לתוויות האמת. ממצא מעניין בלט בתקופת הזמן הקצרה ביותר שנבדקה – השבוע בין 22 ל-29 באוגוסט – שדווקא הניבה את התוצאות הגבוהות ביותר, למרות שמספר הדגימות היה קטן. ככל הנראה, הסיבה לכך היא שהיה זה שבוע גשום במיוחד, דבר שהעצים את האות הרלוונטי במידע והקל על זיהוי תבניות. לעומת זאת, חלונות זמן רחבים יותר כוללים פרקי זמן "יבשים", המדללים את הסיגנל ויוצרים קושי בזיהוי.

2. בחינת רדיוס – בין תועלת לרעש

בהיבט המרחבי, התקבלה תובנה מעניינת: לרוב, רשת לינקים ברדיוס של 1 ק"מ הפגינה ביצועים טובים מאוד – במיוחד סביב מד Bergsj. ערכי QWK היו גבוהים (מעל 0.87), השגיאות נמוכות, והרשת הצרה הצליחה לזהות היטב גשם קל ובינוני. הרחבת הרשת ל-1.5 ק"מ או 2 ק"מ לא הביאה בהכרח לשיפור – ולעיתים אף נצפתה ירידה בביצועים, במיוחד ב-recall של קטגוריה 2. כלומר, הגדלת כמות הלינקים לא תמיד מובילה לתוספת מידע איכותי – ולעיתים אף מכניסה רעש כתוצאה מהבדלים גיאוגרפיים או אזוריים.

עם זאת, חשוב להימנע מהסקת מסקנות חד-משמעיות: המרחק לבדו אינו הממד האידיאלי. ישנם לינקים קרובים, כמו לינק 164 שהינו הלינק הקרוב ביותר למד גשם Jarn, שמדדו נתונים רועשים ולא מייצגים, בעוד שלינקים מרוחקים יותר הצליחו לתרום משמעותית. המשמעות היא שיש לבחון לא רק את המיקום אלא גם את איכות הלינק והמתאם שלו עם מד הגשם בפועל.

3. התאמה דינמית של הרדיוס לכל אזור

מסקנה מהותית העולה מהניתוח היא שלכל מד גשם ייתכן שקיים רדיוס אופטימלי משלו, אשר תלוי במאפיינים כגון טופוגרפיה, צפיפות לינקים, ואיכות מד הגשם המקומי. לכן, לא נכון להפעיל רשת אחידה לכל האזורים – אלא יש להתאים את רדיוס השילוב בצורה פרטנית ודינמית בהתאם לנתוני השטח. גישה זו תאפשר למקסם את איכות התחזיות ולצמצם השפעות של מדידות שגויות או רעש.

4. השוואה בין מדי הגשם

בהסתכלות על שני מדי הגשם, Bergsj ו-Jarn, ניתן לזהות הבדל מובהק בתרומת הרדיוס המרחבי לביצוע התחזיות. במד Bergsj, הרחבת הרשת ל-2 ק"מ תרמה לשיפור קל ומתמשך במדדים המרכזיים: ערכי QWK עלו מ-0.826 ברדיוס של 1 ק"מ ל-0.845 ברדיוס של 2 ק"מ, RMSE ירד מעט, ונרשמה עלייה ב-recall במיוחד עבור קטגוריה 3 (גשם כבד) – תוצאה שלא הופיעה כלל ברדיוס הצר.

שיפור זה מעיד על כך שהוספת לינקים מרוחקים תרמה לחשיפה רחבה יותר לאירועי גשם משמעותיים ושילוב מידע מגוון היטיב עם הזיהוי. לעומת זאת, במד Jarn, הרחבת הרשת לא הובילה לשיפור דומה ואף גרמה לירידה מסוימת ב-QWK, ככל הנראה בשל רעש שהתווסף מהלינקים המרוחקים – ייתכן עקב שונות טופוגרפית או איכות נמוכה של חלק מהלינקים.

ממצאים אלו מדגישים את החשיבות בהתאמה גמישה של רדיוס הרשת לכל אזור: בעוד שב-Bergsj רדיוס רחב סיפק יתרון, ב-Jarn נדרש תכנון מדויק יותר. המשמעות היא שלכל מד גשם קיים ככל הנראה רדיוס אופטימלי, התלוי במבנה המרחבי, צפיפות הלינקים, אורכי הלינקים, ואיכות המדידות המקומיות – ולכן כדאי לאמץ גישה מותאמת אישית ולא לקבוע רדיוס אחיד.

לסיכום, הרחבת המודל מרמת הלינק היחיד לרשת לינקים אזורית סיפקה שיפור ברור בדיוק התחזיות, בהורדת השגיאות, ובזיהוי אירועים משמעותיים. עם זאת, מדובר בתהליך הדורש כיוול מדויק של פרמטרים – ובעיקר של מרחק הלינקים ומידת

תרומתם לתחזית. רשת צפופה ואיכותית יכולה לספק תחזיות אמינות יותר מאשר תצפית נקודתית אחת, אך חשוב להפעיל שיקול דעת ולהימנע מהרחבת יתר העלולה להכניס רעש. התאמה דינמית של מבנה הרשת לאזור תאפשר להשיג את האיזון הרצוי בין עושר מידע לרמת דיוק גבוהה.

חשוב להדגיש כי המודל שאנו מפעילים **שונה עבור כל לינק ברשת**: כל לינק עובר תהליך אימון עצמאי על בסיס הדאטה הייחודי לו, כך שאין מודל אחד כולל, אלא אוסף של מודלים שונים שלומדים כל אחד באופן מקומי. גישה זו מאפשרת התאמה גמישה למאפייני כל לינק, אך יוצרת גם שונות בין התחזיות – ולכן מנגנון שילוב כמו חציון הופך קריטי להשגת יציבות.

עוד יש לציין כי המודל נבחן באמצעות השוואה לנתוני מדי הגשם – אך אלה אינם מושלמים, ועלולים לכלול שגיאות או חוסר התאמות. בפרט ברדיוסים קטנים ייתכן שמד הגשם אינו לוכד אירוע מקומי שהתרחש באזור, או להפך – שאירוע נקודתי במד לא משתקף בלינקים הסובבים. לכן, יש לראות במד הגשם **מקור אמת משוער (proxy)** ולא כ-ground truth מוחלט.

לסיכום, המודל שהצגנו מהווה בסיס מבטיח לפיתוח מערכות חיזוי מרחביות, עם פוטנציאל ליישומים מבצעיים כמו ניתוח היסטורי של משקעים. יחד עם זאת, נדרשת התאמה חכמה של הרשת לפי איכות הנתונים, ושקלול נכון בין לינקים חזקים לחלשים. הגישה שלנו מדגימה כיצד שילוב מודלים מרובים לרשת אחת מאפשר התמודדות עם שונות ורעש – ומציעה כיוון חדש ומבטיח לעיבוד אותות סביבתיים מבוזזים.

רשת לינקים מול לינק בודד: יתרונות, אתגרים ותובנות מהשוואת ביצועים

המעבר ממודל חיזוי מבוסס לינק בודד למודל מרחבי המבוסס על רשת של לינקים סביב מד גשם, נבחן בפרויקט בהשוואה שיטתית בין הביצועים של כל גישה. הממצאים מצביעים על כך שלשילוב תחזיות ממספר לינקים יש יתרונות ברורים, לצד אתגרים מסוימים שיש להביא בחשבון.

● שיפור דיוק ועמידות באמצעות שילוב מרחבי

מן ההשוואה עלה כי **רשת הלינקים מצליחה להניב תוצאות מדויקות ויציבות יותר לעומת לינקים בודדים**, גם כאשר חלק מהלינקים עצמם אינם מדויקים במיוחד. לדוגמה עבור שבוע שנבדק, לינק 530 הציג בפני עצמו תוצאה חלשה יחסית במדד $QWK \approx 0.298$, בעוד לינקים 163 ו-249 דווקא הציגו QWK גבוה מאוד (0.905 ו-0.882 בהתאמה). השונות בין הלינקים מדגישה את התלות באיכות הספציפית של כל אחד מהם.

במודל הרשת לעומת זאת, התקבל QWK של כ-0.878 – כלומר, גם כאשר יש לינק אחד "פחות טוב" **שילוב הלינקים מספק חיזוי עמיד יותר לשונות המקומית** ומייצר תוצאה כללית איכותית. זהו ביטוי לעקרון "חוכמת ההמון" – שילוב של מספר תחזיות, גם אם חלקן פחות מדויקות, עשוי להניב תחזית סופית טובה יותר.

● פיצוי על טעויות נקודתיות

כאשר פועל מודל מבוסס לינק בודד, כל רעש או חריגה במדידה משפיעה ישירות על התחזית. לעומת זאת, ברשת, תחזית הקצה מתבצעת לפי החציון של מספר תחזיות – מה שמנטרל השפעות חריגות בודדות ומבליט את "האות המשותף" המייצג באמת את תנאי הגשם. תהליך זה תורם לאמינות התחזית ומצמצם את הסיכון לשגיאות חריגות, במיוחד באירועים נדירים או גבוליים.

● התמודדות עם שונות בין לינקים

הטבלה מדגימה עד כמה **יש שונות בין לינקים** גם בתוך אותו אזור: חלקם מציגים דיוק גבוה מאוד, בעוד אחרים – כמו לינק 530 או 76 מפיקים תוצאות חלשות מאוד. במצבים כאלה, קשה לדעת מראש איזה לינק הוא "מוביל", ולכן **שילוב לינקים סביבתיים מאפשר לפצות על חולשה של לינק מסוים** על ידי חפיפת מידע עם אחרים.

● יתרון בזיהוי גשם חלש וקטגוריות גבוליות

מהריצות ברשת ניכר כי גישת השילוב שיפרה את ה-recall בקטגוריות מאתגרות, כמו גשם קל (קטגוריה 1), בהן קשה לאתר את אותות הגשם בגלל עמעום חלש. לינק בודד עשוי לפספס אירועים כאלה, אך שילוב מספר לינקים עם אותות חלשים מאפשר זיהוי מדויק יותר של האירוע בזכות הצטברות האינדיקציות.

• יציבות לאורך זמן סקלבליות

רשת הלינקים מציגה לא רק שיפור ברגע נתון, אלא גם **עמידות לאורך זמן**: התחזיות פחות רגישות לתנודתיות של לינק יחיד, והתוצאה המשולבת שומרת על עקביות גם ברצפי זמן ארוכים. בנוסף, חישוב החציון פשוט יחסית ליישום, ואינו דורש אימון חדש או שינוי משמעותי במבנה הדאטה – המאפשר **הרחבה קלה (סקלבליות)** לרשתות צפופות יותר או אזורים גיאוגרפיים שונים.

• חסרונות ואתגרים


לצד היתרונות, קיימים גם אתגרים מהותיים. בראשם – **העלות החישובית** הגבוהה הכרוכה בהרצת מודלים נפרדים לכל לינק ברשת, לעומת מודל בודד. בנוסף, לא כל לינק תורם בפועל תרומה משמעותית לתחזית: חלק מהלינקים אף עלולים להכניס **"רעש" תחזיתי**, גם אם הם קרובים גאוגרפית למד הגשם. הדבר מדגיש כי **איכות הלינק חשובה לא פחות ממיקומו**.

במהלך העבודה זיהינו שלמאפיינים פיזיים של הלינק עשויה להיות השפעה על איכות התחזית. לדוגמה, **אורך הלינק** משפיע על רגישותו לעמעום – לינקים ארוכים נוטים לקלוט יותר רעשי רקע, אך גם עשויים להגיב טוב יותר לגשם מתמשך. בנוסף, **כיוון התדר** (Channel A או B) עשוי להשפיע על איכות הקליטה, כיוון הקרינה, או הפרעות חיצוניות. לכן, בעת בניית רשת לינקים סביב מד גשם, **יש לשקול לא רק את המרחק, אלא גם משתנים פיזיים וטכניים נוספים**, תוך שימוש במנגנוני סינון חכמים לבחירה מושכלת של הלינקים שישולבו במודל.

סיכום

המודל המרחבי המבוסס על רשת לינקים מראה שיפור מובהק בעמידות, ביצועים ודיוק ביחס ללינק יחיד – בעיקר באירועים גבוליים או כאשר יש שונות בין הלינקים. עם זאת, יעילות השיטה תלויה מאוד בהרכב הלינקים, ולכן נדרשת גישה זהירה בבחירה ושילוב של מקורות מידע. השילוב בין מודלים עצמאיים מקומיים לבין מיזוג חכם מהווה תשתית מבטיחה ליישומי חיזוי סביבתי מדויקים, הניתנים להרחבה ולהתאמה למגוון תרחישים.

נוכל להציג את תוצאות רשת הלינקים ברדיוס 1 ק"מ עבור מד גשם JARN בשבוע הנבדק:



מודל מאוחד: גישה אלטרנטיבית להתמודדות עם מגבלת הגנריות

לאורך מרבית שלבי הפרויקט, אימנו מודלים נפרדים לכל לינק, מתוך מטרה להתאים את המודל למאפיינים הייחודיים של כל לינק. שיטה זו, מבוססת על התאמה לוקאלית, הביאה לביצועים טובים אך יצרה מגבלה מהותית: **היעדר גנריות ויכולת הכללה**. מאחר שכל מודל התאמן על דאטה מלינק ספציפי, קשה ליישם את המודל על לינקים חדשים שלא נכללו באימון, או ליצור חיזוי עקבי באזורים מרוחקים.

כדי להתמודד עם אתגר זה, פיתחנו **מודל מאוחד**, בו כלל הלינקים הסמוכים למד גשם נתון מוזגו לטבלה אחת רחבה – בה כל לינק מיוצג באמצעות עמודות נפרדות של ממוצע ושונות, בצירוף פיצ'רים דינמיים הנגזרים מהם. כך, מתקבל מבנה נתונים בו כל שורת זמן מכילה את כלל המידע הנדרש לצורך חיזוי עוצמת הגשם המודל הלוגיסטי יכול ללמוד במקביל גם את הדינמיקה של כל לינק, וגם את **הקשרים הרחביים** ביניהם.

באופן עקרוני, מודל זה מגלם שתי תועלות מרכזיות:

1. **שיפור הגנריות** – המודל נחשף לדפוסים המשותפים בין לינקים שונים, ולכן עשוי ללמוד תבניות כלליות המאפשרות תחזית גם כאשר תנאי השטח משתנים.
2. **יעילות חישובית** – במקום להפעיל עשרות מודלים נפרדים, ניתן להשתמש במודל לוגיסטי יחיד, שפועל על כלל הפיצ'רים בוד'זמנית.

מבחינה טכנית, המודל בוצע בשני שלבים:

- תחילה הופקו כל הקבצים הרלוונטיים של לינקים סמוכים (בהתאם לרדיוס שנבחר) ואוחדו לקובץ באמצעות מיזוג על ציר הזמן.
- לאחר מכן בוצעה **הנדסת פיצ'רים רוחבית** לכל עמודת לינק: חישוב שיעור שינוי, ממוצעים נעים, נגזרות, שוקים, יחסים בין ממוצע לשונות, ועוד. הפיצ'רים חושבו באופן סיסטמטי עבור כל לינק, תוך שמירה על עקביות במבנה.

לבסוף, הופעל **מודל רגרסיה לוגיסטית מולטי־קלאס** על כלל הנתונים, כאשר הפלט הוא תחזית של קטגוריית הגשם (0–3) עבור כל חלון זמן.

יתרונות ואתגרים

גישה זו מהווה ניסיון מובהק לשלב בין התאמה מקומית להבנה גלובלית. המודל מזהה אילו לינקים תורמים יותר לתחזית, דרך ניתוח החשיבות היחסית של הפיצ'רים (על בסיס מקדמי הרגרסיה), ומאפשר אינטגרציה רוחבית של מידע – בדומה לרשת לינקים, אך במודל אחד רציף.

היתרון העיקרי בגישה זו הוא האפשרות ללמוד תבניות מרחביות מורכבות יותר – כאלו המתייחסות לקשרים הדדיים בין לינקים שונים, ולא רק למאפייניו של לינק בודד. המודל המאוחד מסוגל לא רק לשקלל תכונות גשם בכל לינק אלא גם להבין את הדינמיקה הכוללת של הרשת כולה.

עם זאת, הגישה אינה חפה מקשיים. ראשית, **שונות גבוהה באיכות הלינקים** עלולה להכניס רעש לתוך המודל – במיוחד אם לא בוצע סינון מקדים לקביעת הלינקים האמינים. שנית, מאחר שהמודל מאומן על דאטה ספציפי ממד גשם מסוים, **קשה להכליל אותו לאזורים אחרים מבלי לאמן אותו מחדש**. בנוסף, ככל שהרשת מתרחבת וכוללת עשרות לינקים, מספר הפיצ'רים גדל משמעותית – דבר שעשוי להוביל לעומס חישובי ולבעיות של רגרסיה יתרה (overfitting) ללא רגולריזציה מתאימה. כמו כן, ייתכן כי חלק מהפיצ'רים שפיתחנו בעבור מודלים לוקאליים (בהם כל לינק נלמד בנפרד) **אינם מטוייבים או מתאימים לתצורה המאוחדת**. הפיצ'רים תוכננו ללכוד דינמיקות נקודתיות, ואינם בהכרח לוקחים בחשבון את התנהגות הרשת כולה או את השונות המובנית בין לינקים שונים. כתוצאה מכך, ביצועי המודל המאוחד עלולים להיות מוגבלים – לא בגלל חולשה במודל עצמו, אלא בגלל אי התאמה בין הפיצ'רים לבין מורכבות הקלט החדש.

לסיכום, מודל הרגרסיה הלוגיסטית בפורמט זה מציע **כיוון מעניין לשיפור הגנריות של התחזית**, תוך שמירה על פשטות חישובית ויכולת ניתוח פיצ'רים. יחד עם זאת, מומלץ לשלבו עם תהליכי סינון חכמים של לינקים ולהפעילו תוך בחינת התפלגות התוויות, איכות המדידות, והמבנה הטופוגרפי של האזור הרלוונטי.

להלן תוצאות המודל בזמנים שונים עבור רשת לינקים במרחק 1 ק"מ של מד גשם JARN :

מדד שגיאה	שבוע	חודש	3 חודשים
MAE	0.055	0.022	0.024
RMSE	0.267	0.152	0.159
QWK	0.824	0.851	0.810
recall Category 1	0.52	0.44	0.45
recall Category 2	0.74	0.62	0.61
recall Category 3	0.33	0.25	0.22

בהשוואה בין מודל הרשת הקודם – שבו הופעלה רגרסיה לוגיסטית על כל לינק בנפרד ולאחר מכן חושב החציון לצורך התחזית הסופית – לבין המודל המאוחד, בו שולבו כלל הלינקים לתוך רגרסיה אחת כוללת, עולה תמונה מעניינת. המודל המאוחד השיג ביצועים דומים ולעיתים אף טובים יותר במדדים כמו QWK ו-recall לקטגוריות 1 ו-2, אך יתרונו המרכזי בלט בזיהוי קטגוריה 3 (גשם כבד). בעוד שבמודל החציון לא התקבל כלל recall עבור קטגוריה זו, במודל המאוחד נרשמה יכולת תחזית עבור קטגוריה זו בכלל הזמנים. נראה כי שילוב הלינקים במסגרת רגרסיה אחת איפשר למודל לזהות אותות מורכבים או מפוזרים יותר, שלא באו לידי ביטוי דרך חישוב חציון בלבד.

עם זאת, ככל שחלון הזמן התארך – נצפתה ירידה כללית בביצועים, תופעה שהופיעה גם במודל הרשת החציוני. ממצא זה מחזק את ההנחה כי איכות התחזית תלויה גם באיכות האירועים עצמם, וכי דאטה "יבש" עלול לדלל את האות התחזיתי.

פיתוח עתידי וסיכום

סיכום הפרויקט ומודל החיזוי שפותח

במהלך הפרויקט פיתחנו מודל רגרסיה לוגיסטית רב-קטגורי (Multiclass Logistic Regression) המבוסס על הנדסת פיצ'רים ייעודית, במטרה לסווג את **עוצמת הגשם** לפי תוויות אמת ממד גשם. בניגוד לגישות מקובלות שבהן מבצעים שיערוך רציף של כמות הגשם (במילימטרים לשעה), בחרנו לפשט את הבעיה ולהפוך אותה לבעיה של **סיווג קטגורי** – כלומר, תחזית של עוצמת הגשם לפי טווחים מוגדרים מראש: ללא גשם, גשם קל, בינוני או כבד. חלוקה זו התבססה על הגדרות מתוך מאמר מדעי רלוונטי, ואפשרה גם התמודדות טובה יותר עם שונות במדידות וגם ניתוח מדדים ברורים (כגון דיוק ו-recall) לכל קטגוריה. הבחירה בגישה קטגורית תרמה ליציבות המודל, להפחתת רגישות לערכי קצה, וליכולת לנתח מגמות איכותיות לאורך זמן. תהליך הלמידה כלל **יצירת תוויות** על בסיס טווחי הגשם, וחישוב שורת פיצ'רים מהותיים לכל נקודת זמן בלינק: ממוצעים וסטיות תקן של עמעום (attenuation), קצב שינוי, תנודתיות, נגזרות, שילובי פיצ'רים, אינדיקטורים לשינויים חדים, פיצ'רי עיכוב ועוד. כל מודל אומן **עבור כל לינק בנפרד**, מה שאיפשר התאמה מדויקת לדפוסי השידור והסביבה הייחודיים לו – אך גם יצר תלות בלינקים בודדים, וחשף את המודל לרעש או שגיאות נקודתיות.

כדי להקטין את התלות הזו, עברנו לגישת **רשת לינקים מרחבית**, שבמסגרתה מופעלים מודלים לכל לינק הנמצא בטווח מוגדר ממד הגשם (למשל 1–1.5 ק"מ), והתחזיות נאספות ונמזגות לפי **החציון**. גישה זו הפחיתה את הרעש המקומי, איזנה תחזיות קיצון, ושיפרה את **הרובסטינות והדיוק** של התחזית המרחבית, בפרט בזיהוי גשם קל ובינוני. עם זאת, המודל לא הצליח לזהות היטב גשם כבד (קטגוריה 3) – ככל הנראה בשל נדירות האירועים, או פיצול התחזיות בין לינקים שונים. כדי להתמודד עם מגבלה זו, פיתחנו בשלב מתקדם יותר גם **מודל מאוחד** שבו כלל הלינקים באזור מוזגו לטבלה אחת רחבה, עם פיצ'רים נפרדים לכל לינק. על טבלה זו הרצנו מודל רגרסיה לוגיסטית אחיד. המודל המאוחד הצליח לזהות טוב יותר את **קטגוריית הגשם הכבד**, ככל הנראה בזכות היכולת ללמוד **תבניות רחביות** בין לינקים שונים – מה שגישת החציון המקומית מתקשה לעשות. עם זאת, גם לגישה זו יש מגבלות, כמו קושי להכליל ללינקים חדשים ורגישות למבנה הקלט.

לסיכום, המודל שפותח בפרויקט מייצג שילוב בין הנדסת פיצ'רים מתקדמת, עיבוד מרחבי וקטגוריזציה של תחזיות – והוא מהווה תשתית מבטיחה ליישומי חיזוי סביבתי, במיוחד כאשר נדרש מענה לאירועים רגישים, גשם קל או שינויים מהירים בתנאי מזג האוויר.

כיווני פיתוח עתידיים והצעות להרחבה

מסקנות הפרויקט מצביעות על מספר כיוונים משמעותיים להמשך פיתוח המערכת. **ראשית, נדרש לבחון מחדש את תהליך הנדסת הפיצ'רים במודל המאוחד**. מאחר שהפיצ'רים שנבנו נועדו לתיאור לינק בודד, ייתכן שאינם אופטימליים להקשרים מרחביים, ולכן מוצע לבצע תהליך טיוב ואיתור פיצ'רים חדש – שיתמקד באינדיקטורים משותפים למספר לינקים, קשרים בין-לינקיים, ותבניות מרחביות. בנוסף, אחת הבעיות שעלו באופן עקבי – בעיקר בתקופות יבשות – **הייתה הנטייה של המערכת להחמיץ אירועי גשם קל (קטגוריה 1) ולסווגם בטעות כ"אין גשם"**. כדי להתמודד עם כך, ניתן לשקול **גישה של תיקוף התחזית הקטגורית באמצעות מודל בינארי הפועל על אותה רשת לינקים**: במקרים של סתירה בולטת בין התחזיות (למשל כאשר התחזית הרב-קטגורית מצביעה על 0, אך הבינארית מזהה גשם), ניתן להפעיל מנגנון תיקון שמרני. גישה זו עשויה לצמצם טעויות רגישות מסוג False Negatives מבלי לערער את יציבות התחזיות הכוללת.

כיוון נוסף הוא **בדיקה של חלונות זמן אדפטיביים**: כיום המודל מבוסס על חלונות זמן אחידים (בפרויקט זה מדובר על חלון זמן של 5 דקות), אך ייתכן שכאשר אותות משתנים בקצב גבוה – נדרש חלון קצר יותר, ובמקרים יציבים – חלון ארוך יותר. התאמה דינמית של גודל החלון עשויה לשפר את דיוק התחזיות ולשמר רזולוציה רלוונטית.

לוח זמנים

אבן דרך	תאריך יעד	תאריך ביצוע בפועל	הערות
הגשת תכנית העבודה	16.12.24	16.12.24	
הגשת דו"ח מעקב (דו"ח אמצע)	7.3.25	7.3.25	
הגשת הדו"ח סופי ופוסטר הפרויקט	17.5.25	19.5.25	
תאריך הצגת הפרויקט			תאריך משוער – ייקבע לאחר הגשת כל מסמכי הפרויקט ואישורם

ביבליוגרפיה

- World Meteorological Organization (WMO). (2021–2023). *Guide to Instruments and Methods of Observation (WMO-No. 8)*. Geneva: WMO.
- Imhoff, R. O., Overeem, A., Brauer, C. C., Leijnse, H., Weerts, A. H., & Uijlenhoet, R. (2020). Rainfall nowcasting using commercial microwave links. *Geophysical Research Letters*, 47(19), e2020GL089365.
- Habi, Hai Victor, and Hagit Messer. "Recurrent neural network for rain estimation using commercial microwave links." *IEEE Transactions on Geoscience and Remote Sensing* 59.5 (2020): 3672-3681.
- OISAC חומרי קורס



נספחים

נספח 1

לינק 530 ומד גשם Jarn עבור 2015.8.22-29 (לינק רועש)



Confusion Matrix:
[[553 2 1 0]
[23 1 3 0]
[14 0 5 0]
[3 0 0 0]]
Accuracy: 92.40%

Classification Report:
precision recall f1-score support
0 0.93 0.99 0.96 556
1 0.33 0.04 0.07 27
2 0.56 0.26 0.36 19
3 0.00 0.00 0.00 3
accuracy 0.92 605
macro avg 0.46 0.32 0.35 605
weighted avg 0.89 0.92 0.90 605



Confusion Matrix:
[[552 4 0 0]
[9 12 6 0]
[0 6 13 0]
[0 0 2 1]]
Accuracy: 95.54%

Classification Report:				
	precision	recall	f1-score	support
0	0.98	0.99	0.99	556
1	0.55	0.44	0.49	27
2	0.62	0.68	0.65	19
3	1.00	0.33	0.50	3
accuracy			0.96	605
macro avg	0.79	0.61	0.66	605
weighted avg	0.95	0.96	0.95	605



לינק 249 ומד גשם Jarn עבור 22-29.8.2015

Percentage of agreement between the binary and multiclass models: 91.46%

Cross-tabulation:

Predicted_Rain_Label	0	1	2
Predicted_Binary			
0	507	0	0
1	49	11	7

49 cases of mismatches between the models were found.

לינק 530 ומד גשם Jarn עבור 22-29.8.2015

Percentage of agreement between the binary and multiclass models: 67.60%

Cross-tabulation:

Predicted_Rain_Label	0	1	2
Predicted_Binary			
0	383	0	0
1	186	2	3

186 cases of mismatches between the models were found.